TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN CƠ - TIN HỌC

PHÂN TÍCH VÀ DỰ BÁO CHUỖI THỜI GIAN LƯU LƯỢNG DÒNG CHẢY SÔNG COLORADO GIAI ĐOẠN 2010–2023

Dương Quang Huy (23001524) – Khoa học dữ liệu
Giảng viên hướng dẫn: GS. Đỗ Minh Đức
Hà Nội, 2026

Tóm tắt. Bài viết phân tích chuỗi lưu lượng ngày của sông Colorado giai đoạn 2010–2023 (5.113 quan sát) và dự báo 7 ngày cho giai đoạn Test 2022–2023. Q1 cho thấy mùa vụ yếu nhưng biến thiên giữa các năm lớn. Q2 xác định 256 ngày vượt Q95, gom thành 15 đợt. Q3 so sánh Naive persistence, Seasonal Naive 365 và LightGBM direct 7; Naive có mean RMSE thấp nhất trên Test (5,31 m³/s), LightGBM gần tương đương (5,33 m³/s). Kết quả là backtest, không phải dự báo vận hành.

1. Dữ liệu và thiết kế đánh giá

Chuỗi gốc gồm 5.113 quan sát ngày, từ 2010/01/01 đến 2023/12/31, không thiếu ngày, không trùng ngày và không có giá trị lưu lượng thiếu. Lưu lượng trung bình là 295,68 m³/s, độ lệch chuẩn 99,32 m³/s, nhỏ nhất 94,39 m³/s và lớn nhất 457,49 m³/s. Q95 tính trên toàn bộ chuỗi là 417,23 m³/s; có 256 ngày vượt ngưỡng (5,01% tương đương 5%), tạo thành 15 đợt liên tiếp. Z tương đương ngưỡng này là 1,224, không phải 1,645; vì vậy không dùng $z > 3$ để thay cho định nghĩa Top 5%.

Dữ liệu được chia theo thời gian, không xáo trộn. Train dùng 2010–2019, Validation dùng 2020–2021 và Test dùng 2022–2023. Mỗi ngày gốc tạo 7 cặp dự báo D+1 đến D+7; cửa sổ mục tiêu không vượt khỏi tập tương ứng. Bảng 1 tóm tắt số ngày gốc. Sau khi chọn mô hình, toàn bộ 2010–2021 được dùng để refit.

Bảng 1: Chia tập theo thời gian

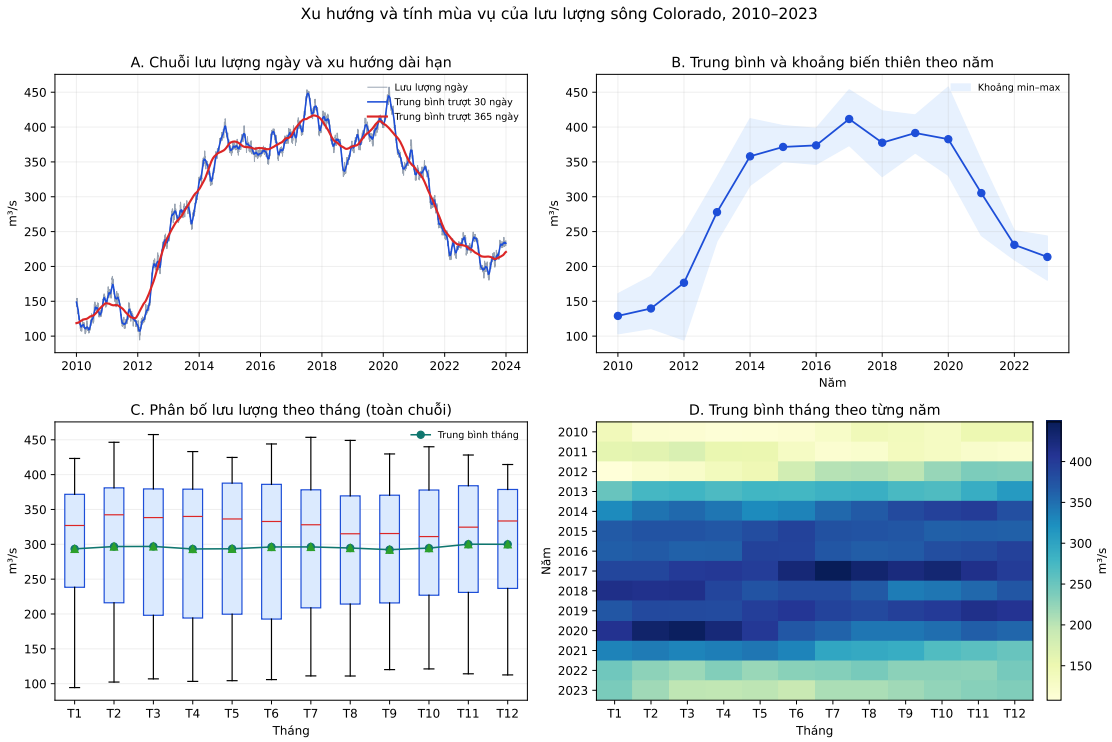
Tập	Khoảng ngày mục tiêu	Số gốc dự báo
Train	01/01/2010–31/12/2019	3.615
Validation	01/01/2020–31/12/2021	725
Refit	01/01/2010–31/12/2021	4.346
Test	01/01/2022–31/12/2023	724

Ba mô hình được so sánh. Naive persistence dùng $\hat{y}(t+h) = y(t)$. Seasonal Naive 365 dùng giá trị cùng ngày của năm trước. LightGBM direct 7 dùng lag 1, 2, 3, 7, 14, 28 ngày; trung bình và độ lệch chuẩn trượt 7, 14, 30, 90 ngày; biến lịch sin/cos của ngày trong năm và tháng; cùng biến lịch của ngày mục tiêu. Mục tiêu của LightGBM là chênh lệch $q(t+h) - q(t)$, sau đó cộng lại vào lưu lượng ngày gốc; đây vẫn là mô hình direct cho từng horizon. Siêu tham số được chọn trên Validation, Test chỉ dùng một lần để báo cáo.

Với mỗi horizon, RMSE, MAE và NSE được tính từng ngày gốc; mean RMSE/MAE/NSE lấy trung bình trên 7 horizon, còn pooled tính trên toàn bộ cặp dự báo. NSE = 1 là hoàn hảo, NSE = 0 tương đương dự báo bằng trung bình và NSE âm là kém hơn mức trung bình.

2. Câu hỏi 1: Xu hướng và mùa vụ

Trung bình tháng thấp nhất là tháng 9 (292,32 m^3/s), cao nhất là tháng 11 (300,16 m^3/s); biên độ trung bình tháng chỉ khoảng 7,84 m^3/s. Trong khi đó, trung bình năm thấp nhất là 2010 (129,01 m^3/s) và cao nhất là 2017 (411,57 m^3/s), biên độ tới 282,57 m^3/s. Biến thiên giữa các năm lớn hơn nhiều so với biên độ mùa vụ trung bình.

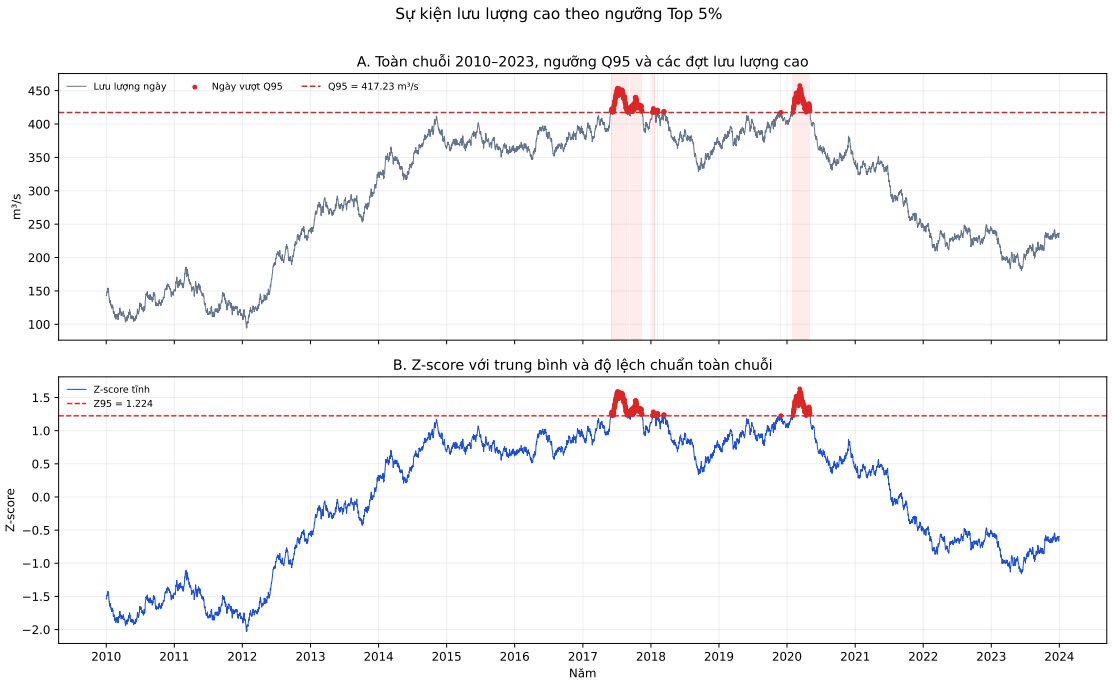


Hình 1: Chuỗi lưu lượng ngày và thành phần xu hướng/mùa vụ. Mùa vụ gần như phẳng; xu hướng thay đổi mạnh theo từng giai đoạn.

STL với chu kỳ 365 ngày và cấu hình robust cho seasonal strength 0,104 và trend strength 0,966. ACF lag 365 ngày là -0,148, rất gần 0; ACF lag 7 ngày và 30 ngày còn cao do tính liên tục ngắn hạn, không phải do mùa vụ năm. Vì vậy không nên đọc chuỗi này như một mùa vụ đều đặn kiểu thủy văn ôn đới. Cần mô tả xu hướng theo từng giai đoạn và nhấn mạnh các năm 2017–2019 có mức lưu lượng cao nổi bật.

3. Câu hỏi 2: Các đợt lưu lượng cao

Q95 toàn chuỗi là 417,23 m^3/s. Có 256 ngày vượt ngưỡng, chiếm 5,01% chuỗi, gom thành 15 đợt liên tiếp. Đợt dài nhất kéo dài 90 ngày; đỉnh lớn nhất trong các đợt là 457,49 m^3/s, thuộc năm 2017. Việc gộp các ngày liên tiếp giúp phân biệt một đợt kéo dài với nhiều dao động ngắn.



Hình 2: Chuỗi lưu lượng và các ngày vượt Q95. Các đợt tập trung chủ yếu quanh 2017–2020.

Bảng 2: Top 5 đợt theo đỉnh lưu lượng

Hạng	Khoảng ngày	Số ngày	Ngày đỉnh	Đỉnh (m³/s)
1	04/02/2020–03/05/2020	90	10/03/2020	457,49
2	13/06/2017–28/08/2017	77	06/07/2017	453,52
3	15/09/2017–14/11/2017	61	11/10/2017	439,97
4	02/09/2017–05/09/2017	4	03/09/2017	423,71
5	13/01/2018–16/01/2018	4	14/01/2018	423,21

Bảng 2 cho thấy đợt dài nhất (90 ngày, đầu năm 2020) không phải đợt có đỉnh lớn nhất; đỉnh lớn nhất nằm trong đợt tháng 6–8/2017. Vì ngưỡng Q95 tính trên toàn chuỗi, số ngày vượt ngưỡng trong một năm cụ thể có thể cao hơn hoặc thấp hơn 5%. Kết quả này chỉ mô tả các đợt trong dữ liệu, không phải phân vùng rủi ro lũ.

4. Câu hỏi 3: Dự báo 7 ngày

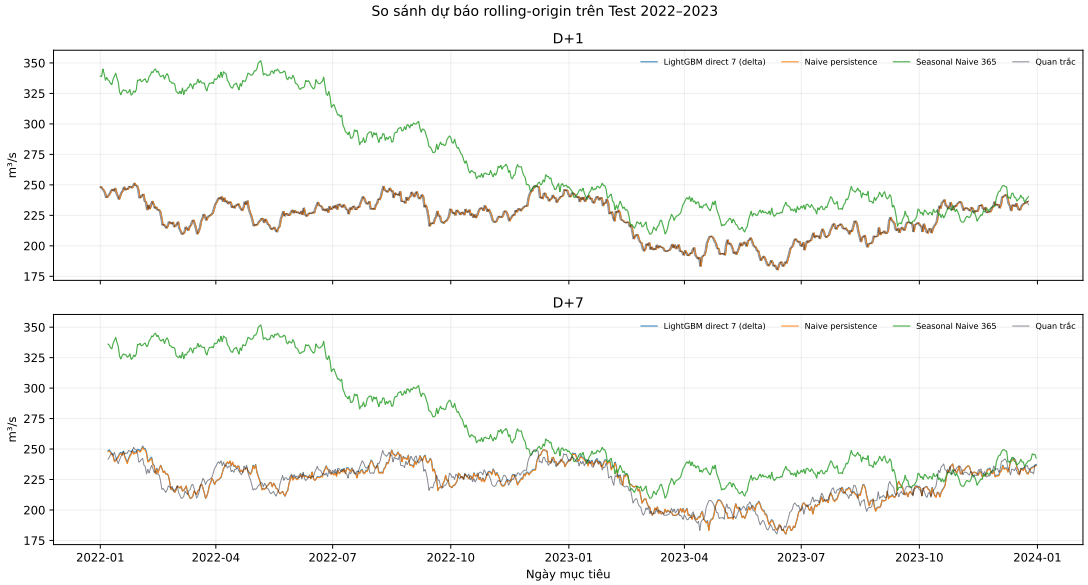
Trên Validation, Naive persistence có mean RMSE 5,535 m³/s, LightGBM delta 5,569 m³/s và Seasonal Naive 365 65,57 m³/s. LightGBM không vượt Naive một cách ổn định; early stopping chọn số vòng lặp rất nhỏ ở một số horizon, cho thấy mô hình gần như quay về persistence. Vì vậy kết quả được báo cáo nguyên trạng, không tinh chỉnh thêm trên Test.

Bảng 3: Chỉ số trên Test 2022–2023 (724 ngày gốc, 5.068 cặp dự báo)

Mô hình	mean RMSE	mean MAE	mean NSE	pooled RMSE	pooled NSE
Naive persistence	5,31	4,16	0,881	5,50	0,882
Seasonal Naive 365	60,48	46,45	-13,333	60,48	-13,333
LightGBM direct 7 (delta)	5,33	4,17	0,881	5,52	0,881

Bảng 3 cho thấy Naive persistence có mean RMSE 5,31 m³/s, thấp hơn LightGBM 5,33 m³/s một chút. Seasonal Naive 365 rất kém (60,48 m³/s), phù hợp với kết luận mùa vụ

yếu ở Q1. Với LightGBM, D+1 có RMSE 2,79 m^3/s và NSE 0,970; D+7 có RMSE 7,10 m^3/s và NSE 0,802. Naive cũng đi từ 2,79 m^3/s ở D+1 lên 7,05 m^3/s ở D+7. Sai số tăng theo horizon là hành vi hợp lý của dự báo chuỗi thời gian.



Hình 3: Backtest 7 ngày: hai panel minh họa D+1 và D+7 với lịch sử, dự báo và giá trị thực tế. Đường dự báo gần như bám mức persistence khi mô hình không tìm thấy tín hiệu vượt trội.

Kết quả này không có nghĩa LightGBM vô dụng. Mô hình vẫn học được cấu trúc phi tuyến và đạt NSE cao, nhưng lợi thế so với persistence không ổn định trên Test. Với chuỗi ngày có độ nhớt cao, baseline mạnh là đối thủ khó thay thế. Nếu mục tiêu là dự báo vận hành, cần bổ sung biến ngoại sinh và đánh giá dài hạn hơn.

5. Thảo luận và giới hạn

Kết quả Q1–Q3 nhất quán với nhau: chuỗi có xu hướng dài hạn mạnh, mùa vụ yếu và các đợt cực trị tập trung ở một số năm. Chính vì mùa vụ yếu, Seasonal Naive 365 thất bại nặng; và vì chuỗi gần random-walk ở tần suất ngày, Naive persistence là baseline mạnh.

Các giới hạn chính:

- Chỉ có 14 năm dữ liệu ngày; Test chỉ 2 năm, chưa đủ cho kết luận dài hạn.
- Chưa dùng biến ngoại sinh như mưa, nhiệt độ, tuyết tan hay vận hành hồ chứa.
- GRU chưa chạy trong môi trường hiện tại; báo cáo không có kết quả GRU.
- LightGBM dùng mục tiêu delta; đây là lựa chọn kỹ thuật đã ghi rõ, không phải kết quả được chọn theo Test.
- Đây là backtest, không phải dự báo vận hành hoặc cảnh báo lũ.

Về mặt phương pháp, việc giữ Test tách biệt và không tinh chỉnh trên Test là điều kiện cần để kết quả có ý nghĩa. Việc Naive thắng LightGBM một chút là kết quả trung thực, không phải lỗi cần che giấu. Nếu tiếp tục phát triển, nên thử mô hình có biến ngoại sinh, kiểm định rolling-origin dài hơn và phân tích sai số theo mùa.

6. Kết luận

Chuỗi lưu lượng sông Colorado 2010–2023 có biến thiên năm lớn hơn nhiều so với mùa vụ trung bình. Q95 toàn chuỗi là 417,23 m^3/s, với 256 ngày vượt ngưỡng trong 15 đợt. Trên Test 2022–2023, Naive persistence đạt mean RMSE 5,31 m^3/s, nhỉnh hơn LightGBM direct 7 (5,33 m^3/s) một chút; Seasonal Naive 365 kém rõ rệt. Kết quả nhấn mạnh tầm

quan trọng của baseline mạnh, chia tập theo thời gian và báo cáo đúng phạm vi back-test.

Phụ lục A. Sai số theo từng horizon

Bảng 4 chi tiết hóa kết quả Test của Naive persistence và LightGBM direct 7. Chạy lại pipeline với cấu hình trong mã nguồn và dữ liệu có mã băm bắt đầu `f83d984747fe` sẽ tái tạo các giá trị này.

Bảng 4: Sai số Test theo horizon (724 ngày gốc mỗi horizon)

Horizon	Naive persistence			LightGBM direct 7		
	RMSE	MAE	NSE	RMSE	MAE	NSE
D+1	2,79	2,23	0,970	2,79	2,23	0,970
D+2	3,93	3,12	0,940	3,93	3,12	0,940
D+3	4,87	3,85	0,907	4,87	3,85	0,907
D+4	5,60	4,42	0,877	5,60	4,43	0,877
D+5	6,23	4,91	0,848	6,25	4,93	0,846
D+6	6,68	5,16	0,824	6,72	5,19	0,822
D+7	7,05	5,40	0,804	7,10	5,45	0,802

LightGBM chỉ nhỉnh hơn Naive ở D+1 (2,79 so với 2,79 m^3/s sau làm tròn) và kém hơn từ D+2 trở đi. Điều này cho thấy mô hình học máy chưa tạo được lợi thế ổn định so với baseline persistence trên giai đoạn Test.

Phụ lục B. Hồ sơ số

Mã nguồn, cấu hình, checkpoint, bảng kết quả và website tĩnh nằm trong `submission.zip`; `source_code.zip` chứa mã và test; `latex_overleaf.zip` chứa toàn bộ source LaTeX. Website chạy cục bộ theo `README.md`; báo cáo không gắn URL công khai chưa được kiểm chứng. Run hiện tại: `run-20261024T160504+0000`; dữ liệu `f83d984747fe`; 14 test Python pass. PDF này được tái tạo từ cùng nguồn và được kiểm tra còn 5 trang.

Tài liệu tham khảo

[1] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.

[2] Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3–73.

[3] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.

[4] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.