ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN – CƠ – TIN HỌC



BÁO CÁO BÀI TẬP 2 – BẢN ĐẦY ĐỦ

PHÂN TÍCH VÀ DỰ BÁO CHUỖI THỜI GIAN LƯU LƯỢNG DÒNG CHẢY SÔNG COLORADO GIAI ĐOẠN 2010–2023

Phân tích dữ liệu chuỗi thời gian, phát hiện cực trị và dự báo 7 ngày

Sinh viên thực hiện: Dương Quang Huy
Mã số sinh viên: 23001524
Môn học: Phân tích dữ liệu chuỗi thời gian
Giảng viên hướng dẫn: GS. Đỗ Minh Đức
Năm học: 2025–2026

Hà Nội, 2026

Tóm tắt

Báo cáo phân tích chuỗi thời gian lưu lượng dòng chảy sông Colorado trong giai đoạn 2010–2023, sử dụng 5.113 ngày quan sát từ 2010/01/01 đến 2023/12/31. Dữ liệu được kiểm tra tính đầy đủ, tính duy nhất và tính liên tục trước khi sử dụng. Báo cáo trả lời ba nhóm câu hỏi: (i) mô tả xu hướng, mùa vụ và cấu trúc tự tương quan của chuỗi; (ii) xác định các ngày và các đợt lưu lượng vượt ngưỡng cực trị Q95; (iii) xây dựng và đánh giá mô hình dự báo trực tiếp 7 ngày, so sánh với các mô hình đơn giản, đồng thời công bố kết quả trên một website tĩnh.

Kết quả chính cho thấy chuỗi có tính dai dẳng rất mạnh: hệ số tự tương quan bậc 7 là 0,926, bậc 30 là 0,694, trong khi tương quan với độ trễ một năm gần như bằng không (-0,148). Phân rã STL cho thấy thành phần xu hướng chiếm ưu thế so với thành phần mùa vụ; biên độ trung bình theo tháng chỉ khoảng 7,84 m^3/s, trong khi biên độ theo năm lên tới 282,57 m^3/s. Ngưỡng Q95 của toàn bộ chuỗi là 417,23 m^3/s, tương ứng 256 ngày vượt ngưỡng (5,01%) và 15 đợt liên tiếp. Đợt dài nhất kéo dài 90 ngày; lưu lượng lớn nhất quan sát được là 457,49 m^3/s.

Với bài toán dự báo 7 ngày, mô hình LightGBM trực tiếp đạt RMSE 5,33 và NSE 0,881 trên tập Test, gần tương đương mô hình Naive (RMSE 5,31, NSE 0,881) và tốt hơn rất nhiều so với Seasonal Naive 365 (RMSE 60,48). Khoảng cách nhỏ giữa LightGBM và Naive cho thấy trong chuỗi này, giá trị gần nhất đã chứa phần lớn thông tin dự báo ngắn hạn; mô hình học máy không tạo ra cải thiện vượt trội. Báo cáo phân tích rõ nguyên nhân, các yếu tố ảnh hưởng theo từng horizon, mức độ quan trọng của đặc trưng và những giới hạn của kết quả.

Toàn bộ mã nguồn, dữ liệu đã xử lý, bảng, hình và báo cáo được công bố tại https://github.com/huyduong5/colorado-river-flow-atlas. Website kết quả có địa chỉ https://huyduong5.github.io/colorado-river-flow-atlas/. Báo cáo không sử dụng GRU/LSTM do môi trường không cài PyTorch; mọi số liệu trong báo cáo đều được sinh lại từ pipeline, không có kết quả mô phỏng hoặc số liệu tự điền.

Từ khóa: chuỗi thời gian, lưu lượng dòng chảy, Q95, STL, LightGBM, dự báo trực tiếp, RMSE, NSE, tái lập.

Nội dung bài tập và phạm vi thực hiện

Bài tập yêu cầu phân tích một chuỗi thời gian thực tế và trình bày kết quả trong một báo cáo có thể tái lập. Ba nhóm câu hỏi được triển khai như sau:

1. **Phân tích chuỗi:** mô tả phân bố, xu hướng dài hạn, tính mùa vụ và cấu trúc tự tương quan của lưu lượng dòng chảy; kiểm tra các giả định về tính dừng và độ dài mùa.
2. **Phát hiện cực trị:** xác định ngưỡng Q95, đếm số ngày vượt ngưỡng, nhận diện các đợt liên tiếp, mô tả phân bố theo năm và theo tháng; kiểm tra độ nhạy của kết quả khi dùng ngưỡng Z-score tĩnh.
3. **Dự báo 7 ngày:** xây dựng mô hình dự báo trực tiếp cho từng horizon, so sánh Naive, Seasonal Naive 365 và LightGBM; đánh giá bằng RMSE, MAE và NSE trên tập Test; phân tích lỗi theo horizon, theo năm và theo mức lưu lượng; công bố bảng, hình và website tương tác.

Phạm vi dữ liệu là 14 năm, từ 2010/01/01 đến 2023/12/31. Tập Test gồm hai năm cuối (2022–2023) và được giữ kín trong toàn bộ quá trình chọn mô hình. Đây là đánh giá backtest trên dữ liệu lịch sử, không phải hệ thống cảnh báo lũ vận hành. Báo cáo không đưa thêm biến ngoại sinh như mưa, nhiệt độ, tuyết tan hoặc vận hành hồ chứa vì bộ dữ liệu đi kèm không có các cột này.

Mục lục

Tóm tắt **i**

Nội dung bài tập và phạm vi thực hiện **ii**

Danh mục từ viết tắt **vii**

1 Dữ liệu, công cụ và quy trình **1**
1.1 Bối cảnh và phạm vi dữ liệu 1
1.2 Cấu trúc và cách đọc dữ liệu 1
1.3 Công cụ và môi trường 2
1.4 Quy trình tái lập 2
1.5 Tiêu chí đánh giá dự báo 2

2 Kiểm tra chất lượng dữ liệu và thiết kế đánh giá **3**
2.1 Kiểm tra tính đầy đủ và tính hợp lệ 3
2.2 Thiết kế chia tập và chống rò rỉ dữ liệu 4
2.3 Các kiểm tra chống rò rỉ 4
2.4 Điểm mạnh và giới hạn của thiết kế 5

3 Câu hỏi 1: Xu hướng, mùa vụ và cấu trúc tự tương quan **5**
3.1 Phân bố và mức nền của chuỗi 5
3.2 Xu hướng và sự thay đổi mức nền theo năm 6
3.3 Phân rã STL 7
3.4 Cấu trúc tự tương quan 9
3.5 Trả lời câu hỏi 1 9

4 Câu hỏi 2: Phát hiện ngày và đợt lưu lượng cực trị **10**
4.1 Định nghĩa ngưỡng cực trị 10
4.2 Kết quả tổng quan 10
4.3 Phân bố theo năm 11
4.4 Phân bố theo tháng 12
4.5 Độ nhạy của ngưỡng 13
4.6 Trả lời câu hỏi 2 14

5 Câu hỏi 3: Dự báo 7 ngày và so sánh mô hình **14**
5.1 Bài toán và chiến lược dự báo 14
5.2 Đặc trưng và mục tiêu delta 15
5.3 Chọn tham số bằng Validation 15
5.4 Kết quả Validation 16

5.5 Kết quả Test tổng thể 16
5.6 Kết quả theo từng horizon 17
5.7 Kết quả theo năm 18
5.8 Mức độ quan trọng của đặc trưng 18
5.9 Chẩn đoán phần dư và ví dụ dự báo 20
5.10 Trả lời câu hỏi 3 21

6 Website kết quả và khả năng tái lập 22
6.1 Mục tiêu và địa chỉ công khai 22
6.2 Kiến trúc website 22
6.3 Các trang và nội dung 23
6.4 Trang dự báo và tương tác 24
6.5 Trang tải về và tính minh bạch 24
6.6 Hiển thị trên thiết bị nhỏ 25
6.7 Triển khai và kiểm tra 26
6.8 Giới hạn của website 26

7 Thảo luận 27
7.1 Điều gì quyết định kết quả? 27
7.2 So sánh với kỳ vọng và tài liệu 27
7.3 Giới hạn dữ liệu và thiết kế 28
7.4 Hướng cải thiện 28
7.5 Ý nghĩa thực hành 28

8 Kết luận 29

Tài liệu tham khảo 30

A Toàn bộ các đợt vượt Q95 31

B Thống kê lưu lượng theo năm 31

C Manifest và kiểm tra tính nhất quán 32

D Hướng dẫn tái lập 32

E Ghi chú về hai phiên bản báo cáo 33

Danh mục bảng

1 Danh mục từ viết tắt dùng trong báo cáo. vii
2 Mô tả các cột dữ liệu gốc và cách xử lý. 1
3 Kết quả kiểm tra chất lượng dữ liệu gốc. 3
4 Các tập huấn luyện, validation, refit và test. 4
5 Thống kê lưu lượng theo tháng trên toàn bộ giai đoạn 2010–2023. . . 6
6 Năm đợt lưu lượng cao dài nhất. Danh sách đầy đủ 15 đợt nằm ở phụ lục. 11
7 Số ngày và số đợt vượt Q95 theo năm. 12
8 Số ngày vượt Q95 theo tháng trên toàn bộ giai đoạn. 13
9 Kết quả 8 lần thử tham số LightGBM trên Validation. 15
10 Chỉ số trên Validation 2020–2021. LightGBM không có pooled validation trong bảng vì bước chọn tham số chỉ lưu chỉ số theo horizon. . . 16
11 Chỉ số dự báo trên Test 2022–2023. Mean là trung bình trên bảy horizon; pooled là tính gộp toàn bộ 5.068 cặp dự báo. 17
12 Chỉ số theo horizon trên Test 2022–2023. 17
13 Chỉ số theo năm trên Test. 18
14 15 đặc trưng có mean gain cao nhất, tổng hợp qua bảy mô hình horizon. 19
15 Các trang chính của website kết quả. 23
16 Toàn bộ các đợt lưu lượng vượt Q95 trong giai đoạn 2010–2023. . . . 31
17 Thống kê lưu lượng theo năm, 2010–2023. 31
18 Thông tin nhận dạng và phiên bản phần mềm của lần chạy. 32

Danh mục hình

1 Phân bố lưu lượng theo tháng. Các hộp chồng lấn mạnh, cho thấy mùa vụ theo tháng yếu so với biến động giữa các năm. 6
2 Diễn biến lưu lượng ngày và trung bình trượt theo năm. Chuỗi có các giai đoạn mức nền thấp, cao và suy giảm rõ rệt. 7
3 Bốn góc nhìn về xu hướng và mùa vụ: (A) chuỗi ngày và xu hướng dài hạn; (B) trung bình và khoảng biến thiên theo năm; (C) phân bố theo tháng; (D) trung bình theo năm và tháng. 8
4 Phân rã STL: (A) chuỗi quan trắc và thành phần xu hướng; (B) thành phần mùa vụ; (C) ACF của chuỗi đã loại xu hướng; (D) phần dư. . . . 9
5 Hai panel: (A) chuỗi lưu lượng và ngưỡng Q95; (B) z-score so với trung bình và độ lệch chuẩn toàn chuỗi. Các điểm vượt ngưỡng tập trung trong 2017–2018 và 2020. 11
6 Bản đồ nhiệt số ngày vượt Q95 theo năm và tháng. Các ô đậm tập trung ở 2017, 2018 và 2020. 13
7 So sánh RMSE, MAE và NSE trên Validation giữa ba mô hình. 16
8 RMSE của LightGBM theo horizon và năm mục tiêu (2022, 2023). . . . 18
9 Mean gain của các đặc trưng LightGBM. 19
10 Phân bố phần dư của LightGBM trên Test. 20
11 Quan trắc và dự báo của LightGBM ở D+1 và D+7, kèm phần dư. . . . 20
12 Dự báo rolling-origin ở D+1 và D+7 trên Test 2022–2023. 21
13 Mã QR đến website kết quả (trái) và kho mã nguồn (phải). 22
14 Trang Tổng quan với các thẻ KPI và tóm tắt phát hiện. 23
15 Trang Dự báo 7 ngày với biểu đồ rolling-origin và bảng chỉ số. 24
16 Trang Tải về với báo cáo, mã nguồn, dữ liệu và checksum. 25
17 Website ở chiều rộng 375 px. 26

Danh mục từ viết tắt

Từ viết tắt	Diễn giải
ACF	Hàm tự tương quan (Autocorrelation Function)
MAE	Sai số tuyệt đối trung bình (Mean Absolute Error)
NSE	Hệ số hiệu quả Nash–Sutcliffe (Nash–Sutcliffe Efficiency)
Q95	Phân vị 95% của lưu lượng trên toàn bộ chuỗi
RMSE	Căn bậc hai sai số bình phương trung bình (Root Mean Squared Error)
STL	Phân rã xu hướng – mùa vụ bằng LOESS (Seasonal-Trend decomposition using LOESS)
LightGBM	Mô hình cây tăng cường gradient của Microsoft
CI/CD	Tích hợp liên tục và triển khai liên tục
SSG	Trang tĩnh được tạo trước (Static Site Generation)

Bảng 1: Danh mục từ viết tắt dùng trong báo cáo.

1. Dữ liệu, công cụ và quy trình

1.1 Bối cảnh và phạm vi dữ liệu

Sông Colorado là một trong những hệ thống sông quan trọng nhất của miền Tây Hoa Kỳ. Lưu lượng dòng chảy tại một trạm quan trắc phản ánh tổng hợp nhiều quá trình: lượng mưa và tuyết rơi trên lưu vực, tốc độ tan tuyết theo mùa, đặc điểm địa hình, lớp phủ thực vật và cả hoạt động điều tiết của hồ chứa. Chuỗi lưu lượng ngày vì vậy thường có tính dai dẳng cao: giá trị hôm nay và những ngày gần nhất có tương quan mạnh với giá trị ngày mai. Tuy nhiên, chuỗi cũng có thể thay đổi mức nền theo năm do điều kiện khí hậu và vận hành hệ thống, tạo ra xu hướng dài hạn và các giai đoạn lưu lượng cao bất thường.

Báo cáo sử dụng tệp `colorado_river_flow.csv` đi kèm bài tập. Tệp có hai cột: `date` (ngày quan trắc) và `discharge_m3s` (lưu lượng, đơn vị m^3/s). Khoảng thời gian từ 2010/01/01 đến 2023/12/31, gồm 5.113 ngày. Bộ dữ liệu không kèm mô tả chi tiết về trạm đo, đơn vị vận hành hay quy trình hiệu chỉnh số liệu; vì vậy báo cáo chỉ phân tích cột lưu lượng được cung cấp và không suy diễn thêm về nguồn gốc hoặc chất lượng đo.

Mục tiêu của phần dữ liệu là trả lời ba câu hỏi kỹ thuật trước khi mô hình hóa: (1) chuỗi có đủ dài và đủ liên tục để phân tích mùa vụ và dự báo hay không; (2) có ngày thiếu, ngày trùng, giá trị null hoặc giá trị bất thường về miền xác định hay không; (3) cách chia Train–Validation–Test có bảo toàn thứ tự thời gian và tránh rò rỉ thông tin hay không. Các câu hỏi này được kiểm tra tự động trong pipeline và kết quả được lưu thành tệp JSON để báo cáo có thể tái lập.

1.2 Cấu trúc và cách đọc dữ liệu

Bảng 2 mô tả hai cột của dữ liệu gốc. Cột ngày được chuyển sang kiểu `datetime` và sắp xếp tăng dần; cột lưu lượng được giữ ở kiểu số thực. Sau khi kiểm tra, dữ liệu được ghi lại thành tệp đã xử lý để các bước sau không phải đọc lại và diễn giải lại dữ liệu thô.

Cột	Kiểu	Ý nghĩa và cách xử lý
`date`	ngày	Ngày quan trắc, định dạng ISO `YYYY-MM-DD`; dùng làm trục thời gian và khóa duy nhất.
`discharge_m3s`	số thực	Lưu lượng dòng chảy, đơn vị m^3/s; giữ nguyên giá trị gốc, không làm tròn khi tính toán.

Bảng 2: Mô tả các cột dữ liệu gốc và cách xử lý.

Vì dữ liệu chỉ có một chuỗi lưu lượng, các phân tích mô tả được thực hiện trên toàn bộ 14 năm. Bài toán dự báo sử dụng cùng chuỗi nhưng chia theo thời gian: Train 2010–2019, Validation 2020–2021 và Test 2022–2023. Cách chia này mô phỏng tình huống thực tế: khi dự báo một ngày trong tương lai, mô hình chỉ được phép dùng thông tin có trước thời điểm đó. Không có phép trộn ngẫu nhiên giữa các

năm, vì trộn ngẫu nhiên sẽ đưa thông tin tương lai vào tập huấn luyện và làm sai lệch đánh giá.

1.3 Công cụ và môi trường

Pipeline được viết bằng Python 3.12, sử dụng `pandas` [7] và `numpy` [8] cho xử lý dữ liệu, `statsmodels` [10] cho phân rã STL và tự tương quan, `lightgbm` [4] cho mô hình cây tăng cường gradient, `matplotlib` [9] cho hình tĩnh và `pytest` cho kiểm thử. Các tham số chính được đặt trong `code/configs/default.yaml`; phiên bản thư viện được ghi trong `code/requirements.lock.txt`. Website kết quả dùng React, TypeScript, Vite và ECharts, được xây dựng thành các tệp tĩnh và triển khai bằng GitHub Pages.

Báo cáo được biên dịch bằng XeLaTeX thông qua Tectonic. Bảng và hình trong báo cáo không được chép tay từ màn hình: chúng được sinh từ kết quả pipeline, sau đó LaTeX chỉ việc chèn nội dung đã sinh. Cách làm này giúp giảm sai lệch giữa số liệu trong báo cáo, số liệu trên website và số liệu trong mã nguồn. Mọi lần chạy lại pipeline đều tạo một `run_id`; báo cáo dùng run run-20261024T160504+0000 để đối chiếu.

1.4 Quy trình tái lập

Pipeline gồm bảy bước có thứ tự:

1. **Audit:** đọc dữ liệu thô, kiểm tra ngày thiếu/trùng, null, giá trị âm, giá trị bằng 0 và tính liên tục của lịch.
2. **EDA:** tính thống kê mô tả, thống kê theo tháng/năm, phân rã STL và tự tương quan.
3. **Features:** tạo lag, rolling window, đặc trưng lịch và biến mục tiêu cho từng horizon.
4. **Train:** huấn luyện LightGBM trên Train, chọn tham số bằng Validation.
5. **Freeze:** khóa cấu hình, tham số và split để tránh thay đổi sau khi đã xem Test.
6. **Evaluate:** dự báo trên Test, tính RMSE, MAE, NSE theo từng horizon, theo năm và theo mức lưu lượng.
7. **Export:** sinh bảng, hình, số liệu LaTeX, manifest và dữ liệu cho website.

Mỗi bước ghi kết quả trung gian vào `code/results`. Nếu một bước bị lỗi, các bước sau không được chạy tiếp. Cách tổ chức này quan trọng với báo cáo vì nó buộc mọi con số phải có nguồn gốc rõ ràng: từ dữ liệu thô, qua cấu hình, đến tệp kết quả và cuối cùng là bảng/hình trong LaTeX.

1.5 Tiêu chí đánh giá dự báo

Ba thước đo được dùng là RMSE, MAE và NSE; NSE được đề xuất trong [3]. Với n cặp giá trị thực y_i và dự báo $\hat{y}_i$:

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}, \qquad \mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|. \tag{1}$$

$$\text{NSE} = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}. \tag{2}$$

RMSE phạt mạnh các sai số lớn và có cùng đơn vị với lưu lượng; MAE dễ diễn giải hơn vì là sai số tuyệt đối trung bình; NSE so sánh mô hình với một dự báo "trung bình" của chính tập đánh giá. NSE bằng 1 là hoàn hảo, bằng 0 là không tốt hơn trung bình, âm là kém hơn trung bình. Vì các horizon có độ khó khác nhau, báo cáo trình bày cả trung bình theo horizon (mean) và giá trị gộp trên toàn bộ cặp dự báo (pooled). Hai cách tính này không thay thế nhau: mean cho biết mô hình tốt đến đâu ở từng horizon, pooled cho biết sai số tổng hợp trên toàn bộ tập Test.

2. Kiểm tra chất lượng dữ liệu và thiết kế đánh giá

2.1 Kiểm tra tính đầy đủ và tính hợp lệ

Bước audit kiểm tra ba khía cạnh: tính liên tục của lịch, tính duy nhất của ngày và miền giá trị của lưu lượng. Kết quả được tóm tắt trong Bảng 3. Chuỗi có đúng 5.113 ngày, không thiếu ngày nào trong khoảng 2010/01/01–2023/12/31, không có ngày trùng và không có giá trị null. Các giá trị lưu lượng đều hữu hạn, dương và không có ngày nào bằng 0. Điều này cho thấy dữ liệu đã được làm sạch ở mức cơ bản và không cần nội suy hoặc loại bỏ quan trắc.

Hạng mục	Giá trị
Số ngày quan trắc	5113
Phạm vi	2010-01-01 – 2023-12-31
Ngày thiếu	0
Ngày trùng	0
Giá trị null	0
Giá trị không hữu hạn	0
Giá trị âm	0
Giá trị bằng 0	0
Chuỗi zero dài nhất	0
Trung bình (m^3/s)	295.6839
Độ lệch chuẩn mẫu (m^3/s)	99.3151
Nhỏ nhất (m^3/s)	94.3909
Q95 (m^3/s)	417.230854
Lớn nhất (m^3/s)	457.486
SHA256	f83d984747fe12e5…

Bảng 3: Kết quả kiểm tra chất lượng dữ liệu gốc.

Một điểm cần lưu ý là báo cáo chỉ kiểm tra chất lượng *kỹ thuật* của tệp dữ liệu, không kiểm tra chất lượng *đo đạc* tại trạm. Việc không có ngày thiếu không có

nghĩa là số liệu đã được hiệu chỉnh theo cùng một quy trình trong suốt 14 năm. Vì vậy các kết luận về xu hướng được trình bày thận trọng, đặc biệt khi so sánh giữa các giai đoạn có mức nền rất khác nhau.

Mã băm SHA256 rút gọn của dữ liệu gốc là `f83d984747fe`; mã đầy đủ được lưu trong `data_quality.json` và được dùng để kiểm tra rằng các lần chạy pipeline sau đọc đúng cùng một tệp. Nếu dữ liệu bị thay đổi dù chỉ một ký tự, mã băm sẽ khác và báo cáo không còn tương ứng với kết quả cũ.

2.2 Thiết kế chia tập và chống rò rỉ dữ liệu

Bài toán được định nghĩa như sau: tại gốc thời gian t, mô hình nhận các quan sát đến hết ngày t và phát hành đồng thời bảy dự báo cho $t+1, \ldots, t+7$. Mỗi cặp (t, h) là một mẫu đánh giá. Cách định nghĩa này phản ánh đúng việc vận hành: tại thời điểm ra quyết định, ta không biết giá trị tương lai, nhưng có thể dùng toàn bộ lịch sử đã quan sát.

Các tập được chia theo thời gian, không xáo trộn:

Tập	Khoảng ngày mục tiêu	Số gốc dự báo
Train	01/01/2010–31/12/2019	3.615
Validation	01/01/2020–31/12/2021	725
Refit	01/01/2010–31/12/2021	4.346
Test	01/01/2022–31/12/2023	724

Bảng 4: Các tập huấn luyện, validation, refit và test.

Tập Train dùng để chọn tham số LightGBM. Tập Validation dùng để chọn cấu hình và đánh giá sơ bộ trong quá trình phát triển. Tập Test chỉ được dùng một lần sau khi cấu hình đã được khóa. Tập Refit gộp Train và Validation để huấn luyện mô hình cuối cùng trước khi dự báo Test. Vì Test nằm hoàn toàn sau Refit, không có quan sát nào của Test được dùng để tính lag, rolling window hoặc chọn tham số.

Số gốc dự báo nhỏ hơn số ngày của mỗi giai đoạn vì hai ràng buộc: cần tối thiểu 30 ngày lịch sử để tính đặc trưng, và cần đủ 7 ngày tương lai để tạo nhãn. Với Train, gốc đầu tiên là 31/01/2010 và gốc cuối là 24/12/2019; với Validation, gốc đầu tiên là 31/12/2019 và gốc cuối là 24/12/2021; với Test, gốc đầu tiên là 31/12/2021 và gốc cuối là 24/12/2023. Các gốc này tạo ra 3.615, 725 và 724 mẫu tương ứng. Tổng số cặp dự báo trên Test là $724 \times 7 = 5.068$ cho mỗi mô hình.

2.3 Các kiểm tra chống rò rỉ

Pipeline thực hiện bốn kiểm tra tự động:

- **Không xáo trộn:** thứ tự thời gian được giữ nguyên; không có phép `train_test_split` ngẫu nhiên.
- **Biên tập:** ngày mục tiêu lớn nhất của Train không vượt quá 31/12/2019; mục tiêu của Validation và Test nằm trong đúng khoảng đã khai báo.

- **Đặc trưng lịch:** các đặc trưng như tháng, ngày trong năm của *ngày mục tiêu* được phép dùng vì chúng biết trước; không dùng bất kỳ giá trị lưu lượng nào của ngày mục tiêu.
- **Khóa cấu hình:** sau khi chọn mô hình, cấu hình và split được ghi vào manifest; các bước evaluate và export chỉ đọc lại cấu hình đã khóa.

Các kiểm tra này không bảo đảm mô hình tốt, nhưng bảo đảm kết quả Test là đánh giá ngoài mẫu đúng nghĩa. Đây là yêu cầu tối thiểu để một báo cáo dự báo chuỗi thời gian có thể được xem là nghiêm túc.

2.4 Điểm mạnh và giới hạn của thiết kế

Thiết kế theo thời gian có ưu điểm là mô phỏng đúng điều kiện triển khai, nhưng cũng có giới hạn. Thứ nhất, chỉ có hai năm Test nên các chỉ số có thể dao động mạnh nếu một năm có chế độ dòng chảy khác biệt. Thứ hai, vì dữ liệu chỉ có một chuỗi, không thể đánh giá khả năng tổng quát hóa sang trạm khác. Thứ ba, các đặc trưng chưa bao gồm biến khí tượng hoặc vận hành hồ chứa, nên mô hình chỉ học được cấu trúc nội tại của chuỗi. Những giới hạn này được quay lại trong phần thảo luận.

3. Câu hỏi 1: Xu hướng, mùa vụ và cấu trúc tự tương quan

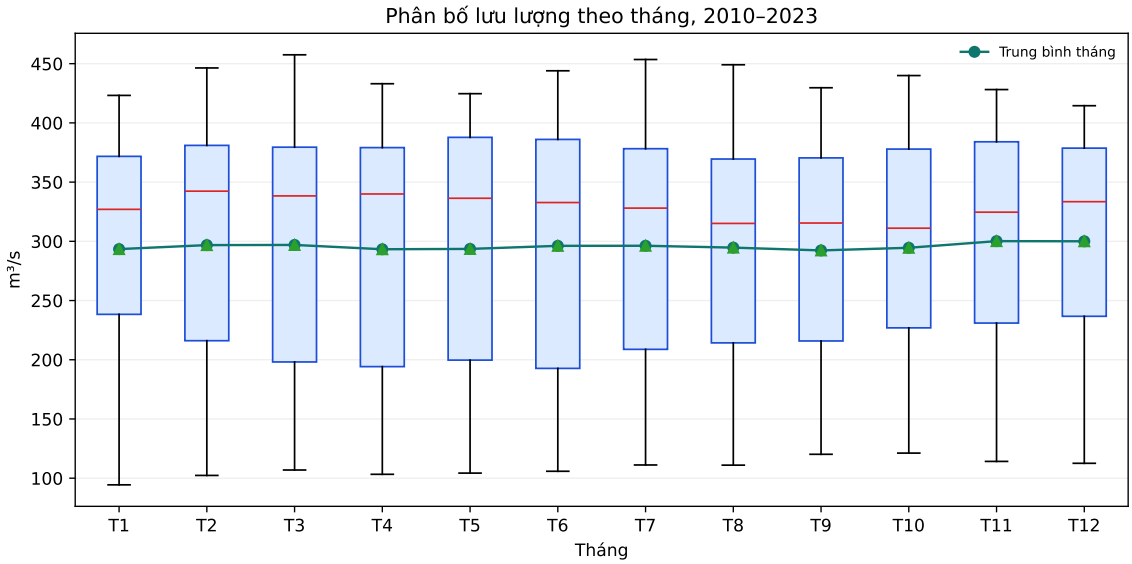
3.1 Phân bố và mức nền của chuỗi

Trong toàn bộ giai đoạn, lưu lượng trung bình là 295,68 m^3/s, trung vị là 334,40 m^3/s, độ lệch chuẩn mẫu là 99,32 m^3/s. Giá trị nhỏ nhất là 94,39 m^3/s và lớn nhất là 457,49 m^3/s. Trung vị lớn hơn trung bình cho thấy phân bố có đuôi thấp dài: phần lớn ngày nằm ở mức trung bình đến cao, nhưng một số giai đoạn lưu lượng rất thấp kéo trung bình xuống. Đây là đặc điểm thường gặp khi chuỗi có nhiều năm hạn hán hoặc khi mức nền thay đổi theo thời kỳ.

Phân bố theo tháng được trình bày trong Bảng 5. Trung bình tháng thấp nhất là 292,32 m^3/s vào tháng 9, cao nhất là 300,16 m^3/s vào tháng 11. Chênh lệch trung bình giữa tháng cao nhất và thấp nhất chỉ khoảng 7,84 m^3/s, tức chưa đến 3% của mức trung bình toàn chuỗi. Tuy nhiên, độ lệch chuẩn trong từng tháng rất lớn, dao động từ 91,79 đến 107,35 m^3/s. Nói cách khác, sự khác biệt giữa các ngày trong cùng một tháng lớn hơn nhiều so với sự khác biệt giữa trung bình các tháng.

Tháng	n	Mean	Median	SD	Min	P25	P75	Max
T1	434	293,44	327,00	99,63	94,39	238,34	371,75	423,21
T2	395	296,80	342,35	106,30	102,33	216,08	381,00	446,39
T3	434	296,95	338,34	107,35	106,91	198,14	379,49	457,49
T4	420	293,31	339,97	104,20	103,28	194,20	379,13	433,06
T5	434	293,59	336,36	103,35	104,30	199,70	387,78	424,66
T6	420	296,18	332,75	104,06	105,84	192,71	386,04	443,99
T7	434	296,25	328,04	100,32	111,16	208,79	378,20	453,52
T8	434	294,69	315,12	93,87	111,01	214,25	369,49	449,08
T9	420	292,32	315,45	92,23	120,18	215,86	370,45	429,67
T10	434	294,55	311,10	94,79	121,19	226,93	377,89	439,97
T11	420	300,16	324,61	93,52	114,17	230,98	384,04	428,14
T12	434	300,04	333,47	91,79	112,57	236,69	378,69	414,51

Bảng 5: Thống kê lưu lượng theo tháng trên toàn bộ giai đoạn 2010–2023.



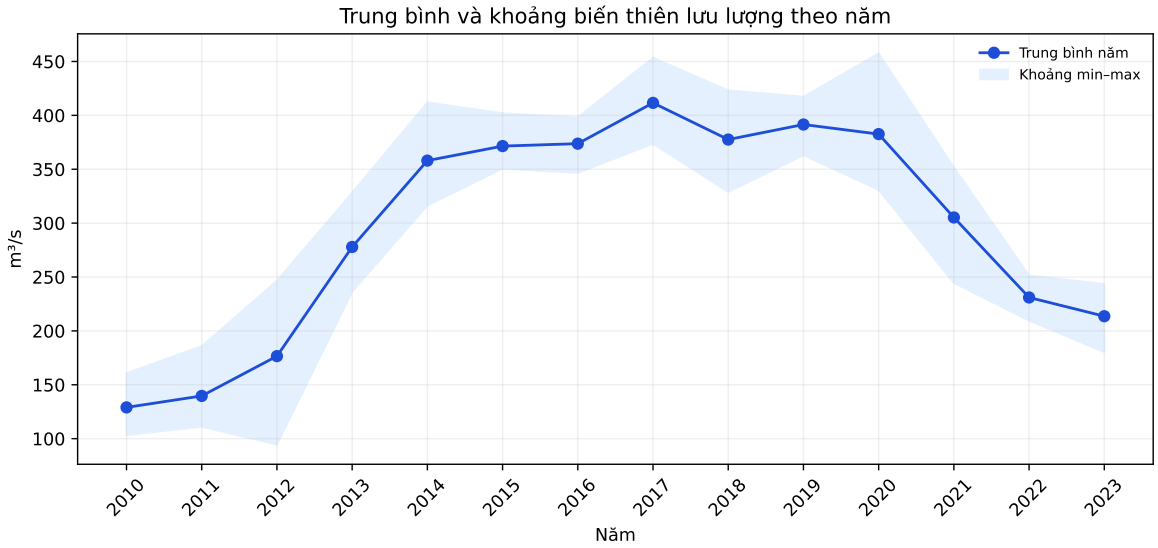
Hình 1: Phân bố lưu lượng theo tháng. Các hộp chồng lấn mạnh, cho thấy mùa vụ theo tháng yếu so với biến động giữa các năm.

Hình 1 cho thấy các hộp phân bố theo tháng chồng lấn gần như hoàn toàn. Tháng 2 và tháng 3 có trung vị cao hơn, tháng 9 và tháng 10 có trung vị thấp hơn, nhưng khoảng tứ phân vị rộng và nhiều giá trị ngoại lai ở cả hai phía. Vì vậy không thể kết luận "mùa lũ" chỉ bằng tháng; cần xem thêm mức nền theo năm và các đợt lưu lượng cao kéo dài.

3.2 Xu hướng và sự thay đổi mức nền theo năm

Bảng 17 (phụ lục) và Hình 2 cho thấy chuỗi không có một xu hướng tuyến tính đơn giản. Giai đoạn 2010–2012 có mức nền thấp, với trung bình năm 2010 chỉ 129,01 m^3/s. Từ 2013 đến 2020, mức nền tăng rõ rệt; năm 2017 đạt trung bình 411,57 m^3/s, cao nhất trong 14 năm. Sau 2020, lưu lượng giảm dần: trung bình năm 2021 là 305,25, năm 2022 là 231,00 và năm 2023 là 213,61 m^3/s. Biên độ trung

bình giữa các năm lên tới 282,57 m^3/s, gấp khoảng 36 lần biên độ trung bình theo tháng.

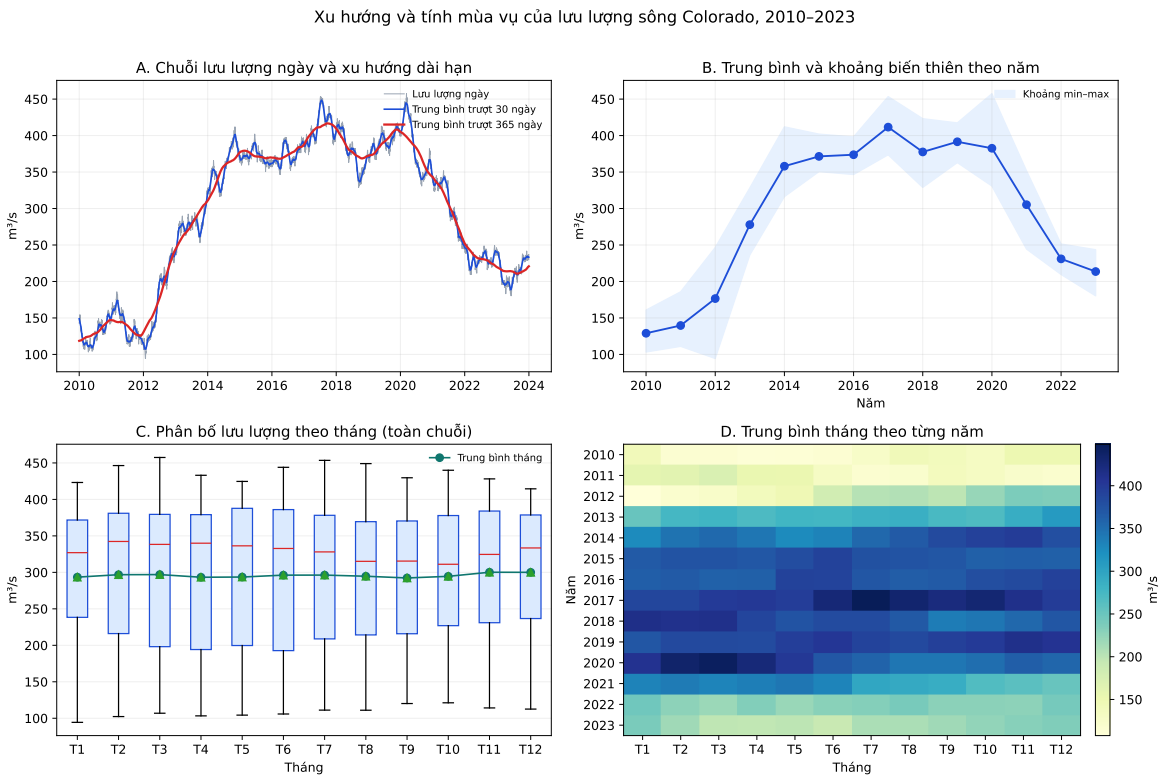


Hình 2: Diễn biến lưu lượng ngày và trung bình trượt theo năm. Chuỗi có các giai đoạn mức nền thấp, cao và suy giảm rõ rệt.

Sự thay đổi mức nền này quan trọng hơn mùa vụ theo tháng. Nếu chỉ nhìn trung bình tháng, ta có thể kết luận chuỗi gần như phẳng; nhưng khi nhìn theo năm, ta thấy các khối nhiều năm với mức lưu lượng rất khác nhau. Đây là lý do chính khiến mô hình Seasonal Naive 365 hoạt động kém trên Test: nó lấy giá trị của cùng ngày năm trước, trong khi mức nền giữa các năm đã thay đổi đáng kể.

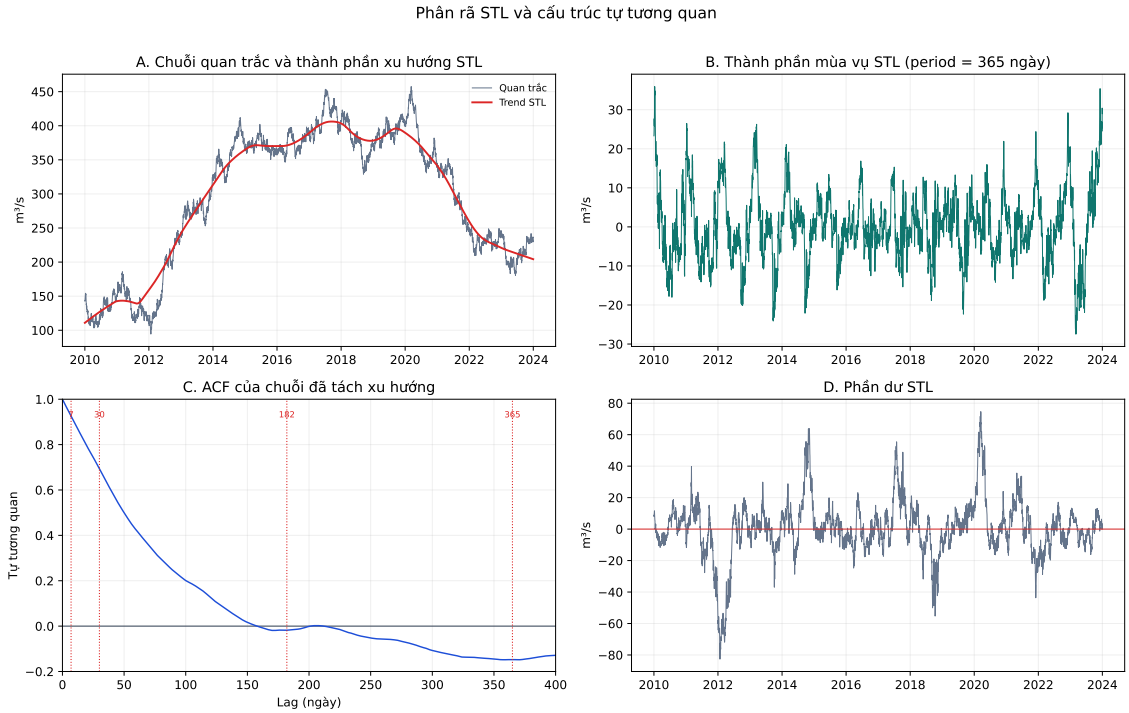
3.3 Phân rã STL

Phân rã STL [2] với chu kỳ 365 ngày và tùy chọn robust được dùng để tách chuỗi thành thành phần xu hướng, mùa vụ và phần dư. Kết quả cho thấy thành phần xu hướng chiếm ưu thế: độ mạnh xu hướng là 0,966, trong khi độ mạnh mùa vụ chỉ là 0,104. Hai giá trị này được tính từ tỷ lệ phương sai của thành phần tương ứng sau khi loại bỏ phần dư; giá trị càng gần 1 thì thành phần đó càng quan trọng.



Hình 3: Bốn góc nhìn về xu hướng và mùa vụ: (A) chuỗi ngày và xu hướng dài hạn; (B) trung bình và khoảng biến thiên theo năm; (C) phân bố theo tháng; (D) trung bình theo năm và tháng.

Thành phần xu hướng bắt đầu ở 110,90 m^3/s, đạt cực đại 406,20 m^3/s và kết thúc ở 204,24 m^3/s. Đây không phải là một đường thẳng tăng đều mà là một đường cong mô tả sự chuyển đổi giữa các chế độ: thấp vào đầu giai đoạn, cao ở giữa và giảm về cuối. Thành phần mùa vụ có biên độ nhỏ, dao động quanh mức vài m^3/s; phần dư vẫn còn biến động đáng kể, phản ánh các sự kiện ngắn hạn và các yếu tố chưa được mô hình hóa.



Hình 4: Phân rã STL: (A) chuỗi quan trắc và thành phần xu hướng; (B) thành phần mùa vụ; (C) ACF của chuỗi đã loại xu hướng; (D) phần dư.

3.4 Cấu trúc tự tương quan

Hàm tự tương quan của chuỗi mức cho thấy tính dai dẳng rất mạnh ở các độ trễ ngắn: ACF bậc 7 là 0,926, bậc 30 là 0,694. Tương quan giảm dần nhưng vẫn còn cao ở các độ trễ hàng tháng. Ở độ trễ nửa năm, ACF gần bằng không (-0,018); ở độ trễ một năm, ACF âm nhẹ (-0,148). Kết quả này cho thấy chuỗi không lặp lại ổn định theo chu kỳ 365 ngày; mùa vụ theo năm không đủ mạnh để tạo tương quan dương ở độ trễ một năm.

ACF giảm chậm là dấu hiệu của chuỗi có mức nền thay đổi hoặc gần với một quá trình có nghiệm đơn vị. Báo cáo không chạy kiểm định ADF/KPSS vì mục tiêu chính là mô tả và dự báo thực nghiệm, nhưng cấu trúc ACF đủ để giải thích vì sao mô hình Naive lại là một baseline mạnh. Giá trị hôm nay chứa rất nhiều thông tin về ngày mai; các mô hình phức tạp chỉ có thể cải thiện nếu chúng học được phần thay đổi nhỏ vượt trên tính dai dẳng đó.

3.5 Trả lời câu hỏi 1

Từ các phân tích trên, có thể kết luận:

- Chuỗi có xu hướng dài hạn dạng chuyển đổi chế độ, không tuyến tính; mức nền tăng từ 2010 đến khoảng 2017–2020 rồi giảm trong 2021–2023.
- Mùa vụ theo tháng tồn tại nhưng yếu: biên độ trung bình theo tháng chỉ 7,84 m^3/s, trong khi biên độ theo năm là 282,57 m^3/s.
- Tính dai dẳng ngắn hạn rất mạnh: ACF bậc 7 là 0,926 và bậc 30 là 0,694; tương quan ở độ trễ một năm âm nhẹ.
- Vì mùa vụ yếu và mức nền thay đổi, các mô hình dựa trên “cùng ngày năm

trước" có nguy cơ sai lệch lớn; các mô hình dùng lag gần và rolling window là lựa chọn hợp lý về mặt cấu trúc, dù kết quả thực nghiệm cho thấy lợi ích so với Naive là rất nhỏ.

Những kết luận này định hướng cho phần dự báo: cần giữ Naive làm baseline, dùng LightGBM với đặc trưng lag/rolling và mục tiêu delta, đồng thời đánh giá riêng từng horizon thay vì chỉ nhìn một chỉ số trung bình.

4. Câu hỏi 2: Phát hiện ngày và đợt lưu lượng cực trị

4.1 Định nghĩa ngưỡng cực trị

Báo cáo dùng ngưỡng phân vị 95% (Q95) của toàn bộ chuỗi 2010–2023 làm định nghĩa "lưu lượng cao". Ngưỡng này là 417,23 m^3/s. Vì Q95 được tính trên toàn bộ dữ liệu, theo cấu tạo sẽ có khoảng 5% số ngày vượt ngưỡng. Kết quả thực tế là 256 ngày, chiếm 5,01%, rất sát với kỳ vọng.

Có thể chuẩn hóa ngưỡng theo trung bình và độ lệch chuẩn:

$$z_{95} = \frac{Q95 - \bar{Q}}{s_Q} = \frac{417{,}23 - 295{,}68}{99{,}32} = 1{,}224.$$

Giá trị này *không* phải 1,645. Trong phân phối chuẩn, phân vị 95% tương ứng với $z \approx 1,645$; nhưng lưu lượng không có phân phối chuẩn và bị lệch. Vì vậy khi báo cáo nói "ngưỡng Z tĩnh", cần hiểu đó là cách chuẩn hóa ngưỡng Q95 theo trung bình và độ lệch chuẩn của chính chuỗi, không phải một kiểm định giả thuyết phân phối chuẩn. Đây là điểm dễ gây nhầm lẫn nếu chỉ nhìn con số 1,224 mà không kiểm tra lại định nghĩa.

Một ngày được gọi là "ngày vượt ngưỡng" nếu lưu lượng lớn hơn Q95. Một "đợt" là dãy ngày vượt ngưỡng liên tiếp; nếu có ít nhất một ngày không vượt ngưỡng ở giữa, đợt được tách thành hai. Cách định nghĩa này đơn giản, dễ tái lập và phù hợp với mục tiêu mô tả. Nó không phân biệt mức độ nghiêm trọng giữa các đợt; vì vậy báo cáo bổ sung số ngày, ngày đỉnh và lưu lượng đỉnh cho từng đợt.

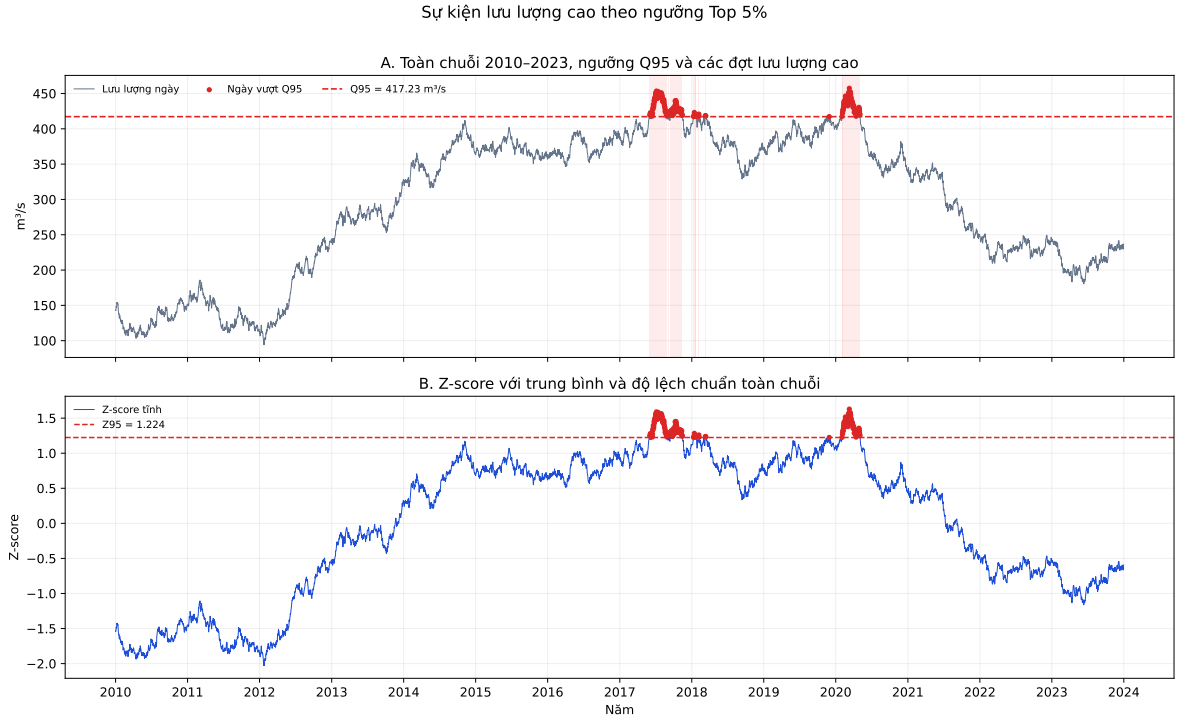
4.2 Kết quả tổng quan

Toàn bộ giai đoạn có 15 đợt vượt ngưỡng. Đợt dài nhất kéo dài 90 ngày, từ 04/02/2020 đến 03/05/2020, với đỉnh 457,49 m^3/s vào ngày 10/03/2020. Đợt dài thứ hai kéo dài 77 ngày, từ 13/06/2017 đến 28/08/2017; đợt dài thứ ba kéo dài 61 ngày, từ 15/09/2017 đến 14/11/2017. Ba đợt này chiếm 228 trong tổng số 256 ngày vượt ngưỡng, tức khoảng 89%.

Hạng	Khoảng ngày	Số ngày	Ngày đỉnh	Đỉnh (m^3/s)
1	04/02/2020–03/05/2020	90	10/03/2020	457,49
2	13/06/2017–28/08/2017	77	06/07/2017	453,52
3	15/09/2017–14/11/2017	61	11/10/2017	439,97
4	02/09/2017–05/09/2017	4	03/09/2017	423,71
5	13/01/2018–16/01/2018	4	14/01/2018	423,21

Bảng 6: Năm đợt lưu lượng cao dài nhất. Danh sách đầy đủ 15 đợt nằm ở phụ lục.

Hình 5 đặt ngưỡng Q95 lên toàn bộ chuỗi thời gian. Các đợt vượt ngưỡng tập trung thành hai cụm lớn: cụm 2017–2018 và cụm 2020. Ngoài hai cụm này, chỉ có một ngày vượt ngưỡng vào cuối tháng 11/2019. Các năm 2010–2016 và 2021–2023 không có ngày nào vượt Q95. Điều này cho thấy cực trị không phân bố đều theo thời gian mà phụ thuộc vào những giai đoạn có mức nền cao.



Hình 5: Hai panel: (A) chuỗi lưu lượng và ngưỡng Q95; (B) z-score so với trung bình và độ lệch chuẩn toàn chuỗi. Các điểm vượt ngưỡng tập trung trong 2017–2018 và 2020.

4.3 Phân bố theo năm

Bảng 7 cho thấy năm 2017 có 148 ngày vượt ngưỡng, chiếm 40,55% số ngày của năm và 6 đợt. Năm 2020 có 91 ngày, chiếm 24,86%, với 2 đợt. Năm 2018 có 16 ngày, 6 đợt; năm 2019 có 1 ngày, 1 đợt. Tổng cộng 2017 và 2020 chiếm 239/256 ngày vượt ngưỡng, tức hơn 93%. Sự tập trung này giải thích vì sao các chỉ số trung bình toàn chuỗi có thể che lấp hành vi cực trị: một vài năm có mức nền cao chi phối phần lớn số ngày vượt ngưỡng.

Năm	Ngày vượt Q95	Tổng ngày	Tỷ lệ (%)	Số đợt
2010	0	365	0,00	0
2011	0	365	0,00	0
2012	0	366	0,00	0
2013	0	365	0,00	0
2014	0	365	0,00	0
2015	0	365	0,00	0
2016	0	366	0,00	0
2017	148	365	40,55	6
2018	16	365	4,38	6
2019	1	365	0,27	1
2020	91	366	24,86	2
2021	0	365	0,00	0
2022	0	365	0,00	0
2023	0	365	0,00	0

Bảng 7: Số ngày và số đợt vượt Q95 theo năm.

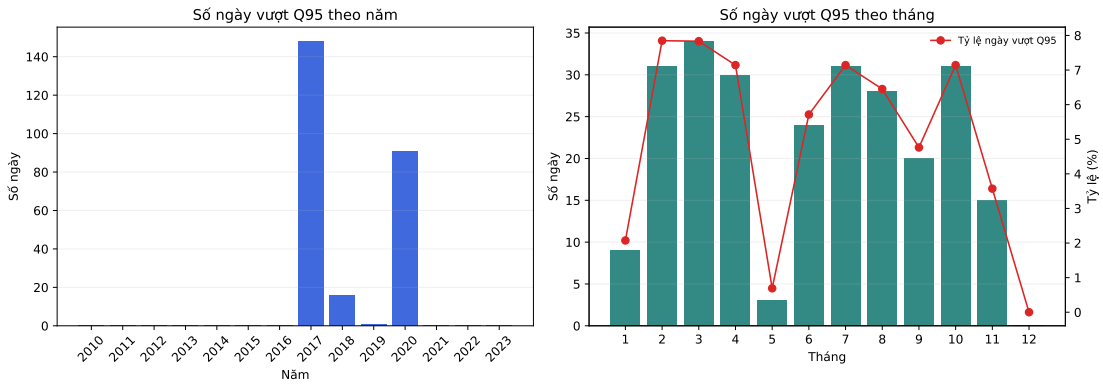
Năm 2018 đáng chú ý vì có 6 đợt nhưng tổng cộng chỉ 16 ngày. Điều này có nghĩa các đợt ngắn, bị ngắt bởi những ngày dưới ngưỡng, thay vì một đợt dài. Ngược lại, năm 2020 chỉ có 2 đợt nhưng một đợt kéo dài 90 ngày. Cùng một số ngày vượt ngưỡng có thể tương ứng với cấu trúc đợt rất khác nhau; vì vậy cần báo cáo cả số ngày và số đợt.

4.4 Phân bố theo tháng

Bảng 8 cho thấy các tháng 2, 3, 4 và 10 có số ngày vượt ngưỡng cao nhất (31, 34, 30 và 31 ngày). Tháng 12 không có ngày nào vượt ngưỡng. Tuy nhiên, không nên suy ra rằng “mùa lũ” chỉ nằm trong các tháng này, vì các đợt lớn có thể kéo dài qua nhiều tháng. Đợt 2020 bắt đầu từ tháng 2 và kéo sang tháng 5; đợt 2017 kéo dài từ tháng 6 đến tháng 11. Vì vậy phân bố theo tháng phản ánh thời điểm bắt đầu và kết thúc của các đợt, không phản ánh một mùa vụ cố định.

Tháng	Ngày vượt Q95	Tổng ngày	Tỷ lệ (%)
T1	9	434	2,07
T2	31	395	7,85
T3	34	434	7,83
T4	30	420	7,14
T5	3	434	0,69
T6	24	420	5,71
T7	31	434	7,14
T8	28	434	6,45
T9	20	420	4,76
T10	31	434	7,14
T11	15	420	3,57
T12	0	434	0,00

Bảng 8: Số ngày vượt Q95 theo tháng trên toàn bộ giai đoạn.



Hình 6: Bản đồ nhiệt số ngày vượt Q95 theo năm và tháng. Các ô đậm tập trung ở 2017, 2018 và 2020.

Hình 6 cho thấy rõ hơn cấu trúc theo năm–tháng. Năm 2017 có nhiều ngày vượt ngưỡng từ tháng 6 đến tháng 11; năm 2018 tập trung vào tháng 1–3; năm 2020 tập trung vào tháng 2–5. Đây là các cụm có ý nghĩa thủy văn, không phải một mùa vụ lặp lại đều đặn. Vì vậy mô hình dự báo cần học từ trạng thái gần nhất và mức nền hiện tại, thay vì dựa vào mùa vụ lịch.

4.5 Độ nhạy của ngưỡng

Ngưỡng Q95 được tính trên toàn bộ chuỗi, không tính lại theo từng năm. Cách làm này phù hợp cho mục tiêu mô tả "đâu là những ngày cao bất thường so với toàn bộ giai đoạn", nhưng có hai giới hạn. Thứ nhất, nếu dùng ngưỡng này để vận hành, ta sẽ dùng thông tin của tương lai để định nghĩa ngưỡng cho quá khứ. Thứ hai, khi mức nền thay đổi mạnh, một ngưỡng cố định có thể đánh dấu quá nhiều ngày ở giai đoạn mức cao và quá ít ngày ở giai đoạn mức thấp.

Một lựa chọn thay thế là ngưỡng trượt theo cửa sổ 365 ngày hoặc ngưỡng theo tháng. Báo cáo không triển khai các phương án này vì mục tiêu của câu hỏi 2 là

mô tả cực trị toàn giai đoạn, không phải xây dựng hệ thống cảnh báo. Tuy nhiên, đây là hướng mở rộng tự nhiên nếu dữ liệu được dùng trong vận hành thực tế. Khi đó cần đánh giá độ nhạy của số đợt, độ dài đợt và đỉnh đợt theo từng cách chọn ngưỡng.

4.6 Trả lời câu hỏi 2

Các kết quả chính:

- Ngưỡng Q95 là 417,23 m^3/s, tương ứng z tĩnh 1,224; có 256 ngày vượt ngưỡng (5,01%).
- Có 15 đợt; đợt dài nhất 90 ngày (2020), đợt dài thứ hai 77 ngày (2017), đợt dài thứ ba 61 ngày (2017).
- Cực trị tập trung vào 2017–2018 và 2020; 2017 và 2020 chiếm hơn 93% số ngày vượt ngưỡng.
- Phân bố theo tháng không tạo thành một mùa vụ cố định; các đợt lớn kéo dài qua nhiều tháng và phụ thuộc vào mức nền từng năm.

Các kết luận này được dùng ở phần dự báo để giải thích vì sao các mô hình có thể dự báo tốt trung bình nhưng vẫn sai lệch trong các đợt cực trị: cực trị là hiện tượng hiếm, tập trung theo cụm và chịu ảnh hưởng của mức nền nhiều năm.

5. Câu hỏi 3: Dự báo 7 ngày và so sánh mô hình

5.1 Bài toán và chiến lược dự báo

Tại mỗi gốc t, mô hình phải đưa ra bảy dự báo $\hat{q}_{t+1}, \ldots, \hat{q}_{t+7}$. Báo cáo sử dụng chiến lược *dự báo trực tiếp* [6]: huấn luyện riêng một mô hình cho mỗi horizon h, thay vì dùng một mô hình đệ quy để dự báo từng bước rồi lấy dự báo trước làm đầu vào cho bước sau. Cách làm trực tiếp tránh tích lũy sai số qua các bước và cho phép mỗi horizon học một quan hệ riêng. Đổi lại, cần bảy mô hình và nhiều tham số hơn.

Ba mô hình được so sánh:

1. **Naive persistence:** $\hat{q}_{t+h} = q_t$ cho mọi h. Đây là baseline bắt buộc trong dự báo chuỗi có tính dai dẳng cao.
2. **Seasonal Naive 365:** $\hat{q}_{t+h} = q_{t+h-365}$, tức lấy giá trị cùng ngày của năm trước. Mô hình này kiểm tra giả thuyết chuỗi có mùa vụ năm ổn định.
3. **LightGBM direct 7:** bảy mô hình cây tăng cường gradient [5, 4], mỗi mô hình dự báo trực tiếp một horizon từ các đặc trưng lag, rolling window và lịch.

Cả ba mô hình đều được đánh giá trên cùng 724 gốc Test và cùng 5.068 cặp (t, h). Việc dùng cùng gốc và cùng horizon bảo đảm so sánh công bằng. Các mô hình không được phép dùng giá trị tương lai; Seasonal Naive chỉ dùng giá trị cách đó đúng 365 ngày, còn LightGBM chỉ dùng các đặc trưng được tạo từ dữ liệu đến ngày t và các đặc trưng lịch của ngày mục tiêu.

5.2 Đặc trưng và mục tiêu delta

Với mỗi gốc, LightGBM nhận 29 đặc trưng cơ bản: giá trị hiện tại q_t; các lag 1, 2, 3, 7, 14, 21, 28 và 30 ngày; trung bình, độ lệch chuẩn, min, max của cửa sổ 7, 14 và 30 ngày; sai phân 1 ngày và 7 ngày; cùng các đặc trưng lịch của ngày gốc (tháng, ngày trong năm, sin/cos). Ngoài ra, mỗi horizon có thêm sáu đặc trưng lịch của *ngày mục tiêu*: tháng, ngày trong năm và các biến sin/cos tương ứng. Các đặc trưng này biết trước nên không gây rò rỉ dữ liệu.

Mục tiêu huấn luyện không phải giá trị tuyệt đối q_{t+h} mà là mức thay đổi $\Delta_{t,h} = q_{t+h} - q_t$. Mô hình dự báo $\hat{\Delta}_{t,h}$, sau đó cộng lại q_t để được mức dự báo. Cách làm này được gọi là *delta target* và có tác dụng "giữ" tính persistence trong mô hình: nếu mô hình học được $\Delta \approx 0$, nó quay về Naive; nếu học được phần thay đổi, nó cải thiện so với Naive. Đây là lựa chọn phù hợp với chuỗi có ACF cao, vì mô hình không phải học lại toàn bộ mức lưu lượng từ đầu.

Cần nhấn mạnh rằng delta target không bảo đảm LightGBM tốt hơn Naive. Nó chỉ giúp mô hình có một điểm khởi đầu hợp lý. Nếu phần thay đổi chủ yếu là nhiễu, mô hình có thể học nhiễu và làm sai lệch nhẹ so với Naive. Kết quả thực nghiệm cho thấy đúng như vậy: LightGBM gần như trùng Naive ở các horizon ngắn và kém hơn một chút ở các horizon dài.

5.3 Chọn tham số bằng Validation

LightGBM được chọn tham số bằng 8 lần thử ngẫu nhiên trên Validation 2020–2021, với seed 42. Không gian tìm kiếm gồm learning rate $\{0{,}03; 0{,}05\}$, số lá $\{7; 15; 31\}$, độ sâu $\{3; 5; -1\}$, min child samples $\{20; 40; 80\}$ và $\lambda \in \{0; 1; 5\}$. Mỗi lần thử huấn luyện bảy mô hình, dùng early stopping 50 vòng và tối đa 1.000 vòng. Tiêu chí chọn là mean RMSE trên bảy horizon.

Trial	LR	Leaves	Depth	Min child	Lambda	mean RMSE	mean MAE	mean NSE
1	0,03	7	-1	40	0,0	5,58	4,45	0,987
2	0,03	7	-1	20	5,0	5,58	4,45	0,987
3	0,03	31	5	20	0,0	5,58	4,45	0,987
4	0,03	7	3	80	5,0	5,58	4,45	0,987
5	0,03	8	3	80	5,0	5,58	4,45	0,987
6	0,05	7	5	80	1,0	5,58	4,45	0,987
7	0,03	7	-1	40	1,0	5,58	4,45	0,987
8	0,05	7	3	40	0,0	5,57	4,44	0,987

Bảng 9: Kết quả 8 lần thử tham số LightGBM trên Validation.

Bảng 9 cho thấy các lần thử có kết quả gần như giống nhau: mean RMSE từ 5,57 đến 5,58 m^3/s. Trial 8 được chọn với learning rate 0,05, 7 lá, độ sâu 3, min child 40 và $\lambda = 0$; mean RMSE là 5,57, mean MAE là 4,44 và mean NSE là 0,987. Khoảng cách giữa trial tốt nhất và trial đầu tiên chỉ khoảng 0,01 m^3/s, nhỏ hơn nhiều so với độ bất định giữa các năm. Vì vậy không nên diễn giải việc "tối ưu tham số" là nguyên nhân chính tạo ra kết quả; yếu tố quyết định là cấu trúc đặc trưng và tính

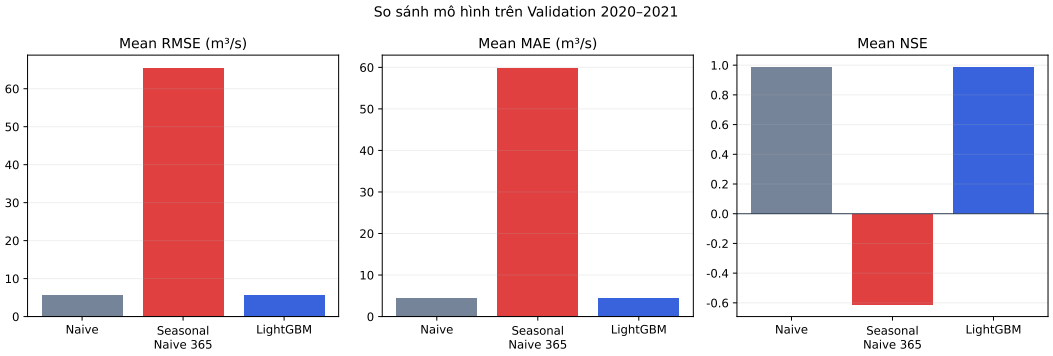
dai dẳng của chuỗi.

5.4 Kết quả Validation

Bảng 10 so sánh ba mô hình trên Validation. Naive có mean RMSE 5,54; LightGBM 5,57; Seasonal Naive 65,57. LightGBM thấp hơn Naive về mean NSE một chút (0,987 so với 0,988). Kết quả này đã dự báo trước kết quả Test: mô hình học máy không vượt được baseline persistence trên dữ liệu ngoài mẫu.

Mô hình	mean RMSE	mean MAE	mean NSE	pooled RMSE	pooled NSE
Naive persistence	5,54	4,42	0,988	5,76	0,988
Seasonal Naive 365	65,57	59,95	-0,612	65,57	-0,612
LightGBM direct 7 (delta)	5,57	4,44	0,987	–	–

Bảng 10: Chỉ số trên Validation 2020–2021. LightGBM không có pooled validation trong bảng vì bước chọn tham số chỉ lưu chỉ số theo horizon.



Hình 7: So sánh RMSE, MAE và NSE trên Validation giữa ba mô hình.

Hình 7 cho thấy Seasonal Naive là mô hình kém nhất trên Validation. Điều này phù hợp với phân tích ở câu hỏi 1: mùa vụ theo năm yếu và mức nền thay đổi, nên việc lặp lại giá trị cùng ngày năm trước tạo sai số lớn. LightGBM và Naive gần như trùng nhau; khoảng cách giữa hai mô hình nhỏ hơn nhiều so với khoảng cách giữa chúng và Seasonal Naive.

5.5 Kết quả Test tổng thể

Bảng 11 là kết quả chính trên Test 2022–2023. Naive có mean RMSE 5,31, MAE 4,16 và NSE 0,881. LightGBM có mean RMSE 5,33, MAE 4,17 và NSE 0,881. Seasonal Naive có mean RMSE 60,48 và NSE $-13,333$. Như vậy, Naive là mô hình tốt nhất theo mean RMSE, nhưng khoảng cách với LightGBM chỉ 0,02 m^3/s, tương đương khoảng 0,3%. Về mặt thực hành, hai mô hình gần như tương đương; về mặt thống kê, cần thêm dữ liệu để khẳng định mô hình nào thực sự tốt hơn.

Mô hình	mean RMSE	mean MAE	mean NSE	pooled RMSE	pooled NSE
Naive persistence	5,31	4,16	0,881	5,50	0,882
Seasonal Naive 365	60,48	46,45	-13,333	60,48	-13,333
LightGBM direct 7 (delta)	5,33	4,17	0,881	5,52	0,881

Bảng 11: Chỉ số dự báo trên Test 2022–2023. Mean là trung bình trên bảy horizon; pooled là tính gộp toàn bộ 5.068 cặp dự báo.

Kết quả pooled cũng cho thấy cùng một bức tranh: Naive pooled RMSE 5,50, LightGBM 5,52, Seasonal 60,48. NSE pooled của Naive và LightGBM đều khoảng 0,881. Việc mean và pooled gần nhau là do mỗi horizon có cùng số cặp dự báo; nếu số cặp giữa các horizon khác nhau, hai cách tính có thể chênh lệch nhiều hơn.

Điểm đáng chú ý là Seasonal Naive rất kém trên Test, đặc biệt năm 2022. Nguyên nhân là mức nền năm 2021 cao hơn nhiều so với 2022; khi lấy giá trị cùng ngày năm 2021 để dự báo 2022, mô hình lặp lại mức cao và tạo sai số lớn. Đây là ví dụ điển hình cho việc một mô hình "có mùa vụ" vẫn có thể thất bại nếu mùa vụ không ổn định hoặc mức nền thay đổi.

5.6 Kết quả theo từng horizon

Bảng 12 trình bày chỉ số theo từng horizon. Với cả Naive và LightGBM, RMSE tăng gần như tuyến tính từ D+1 đến D+7: D+1 khoảng 2,79; D+7 khoảng 7,05–7,10. NSE giảm từ 0,970 ở D+1 xuống 0,802–0,804 ở D+7. Đây là quy luật hợp lý: dự báo càng xa càng khó, vì tính dai dẳng giảm dần và các thay đổi mức nền có nhiều thời gian phát sinh hơn.

Horizon	Naive persistence			LightGBM direct 7		
	RMSE	MAE	NSE	RMSE	MAE	NSE
D+1	2,79	2,23	0,970	2,79	2,23	0,970
D+2	3,93	3,12	0,940	3,93	3,12	0,940
D+3	4,87	3,85	0,907	4,87	3,85	0,907
D+4	5,60	4,42	0,877	5,60	4,43	0,877
D+5	6,23	4,91	0,848	6,25	4,93	0,846
D+6	6,68	5,16	0,824	6,72	5,19	0,822
D+7	7,05	5,40	0,804	7,10	5,45	0,802

Bảng 12: Chỉ số theo horizon trên Test 2022–2023.

Ở D+1, D+2 và D+3, hai mô hình gần như trùng nhau đến hai chữ số thập phân. Từ D+5 trở đi, LightGBM bắt đầu kém hơn một chút: D+7 có RMSE 7,10 so với 7,05 của Naive, MAE 5,45 so với 5,40, NSE 0,802 so với 0,804. Mức chênh lệch này nhỏ nhưng có hệ thống, cho thấy các đặc trưng bổ sung chưa giúp ích cho horizon dài. Một phần nguyên nhân là mô hình delta phải học phần thay đổi nhỏ giữa hai mức lưu lượng, trong khi phần thay đổi này chịu ảnh hưởng của nhiều yếu tố không có

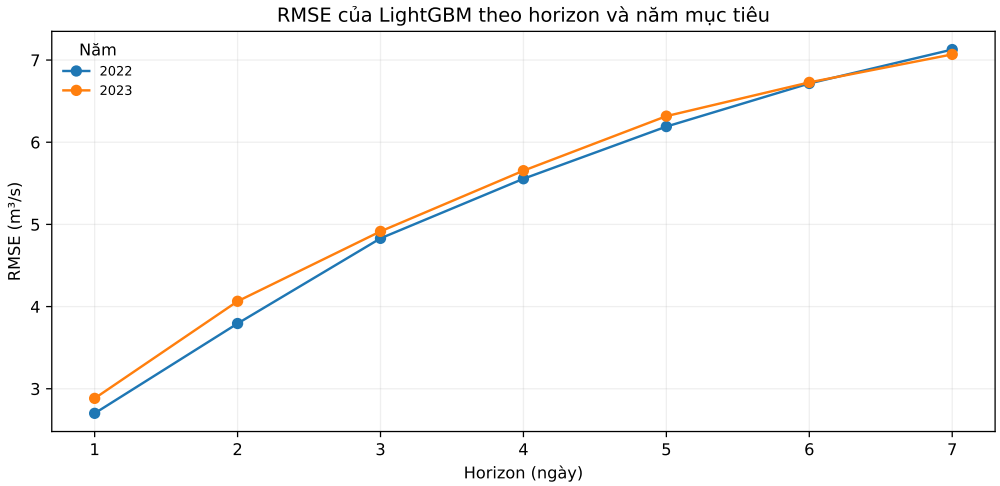
trong dữ liệu.

5.7 Kết quả theo năm

Bảng 13 và Hình 8 cho thấy sai số thay đổi theo năm. Năm 2022 có RMSE khoảng 5,26–5,27 cho Naive và LightGBM, nhưng NSE chỉ khoảng 0,67. Năm 2023 có RMSE cao hơn một chút (5,36–5,38) nhưng NSE cao hơn (0,885–0,886). NSE phụ thuộc vào phương sai của mục tiêu trong từng năm: nếu lưu lượng ít biến động, một RMSE nhỏ vẫn có thể tạo NSE thấp. Vì vậy cần đọc RMSE và NSE cùng nhau, không nên chỉ dựa vào một chỉ số.

Mô hình	Năm	RMSE	MAE	NSE
Naive persistence	2022	5,26	4,12	0,670
Naive persistence	2023	5,36	4,19	0,886
Seasonal Naive 365	2022	82,43	74,10	-74,054
Seasonal Naive 365	2023	22,85	18,79	-0,949
LightGBM direct 7 (delta)	2022	5,27	4,12	0,668
LightGBM direct 7 (delta)	2023	5,38	4,22	0,885

Bảng 13: Chỉ số theo năm trên Test.



Hình 8: RMSE của LightGBM theo horizon và năm mục tiêu (2022, 2023).

Seasonal Naive có RMSE 82,43 vào năm 2022 và 22,85 vào năm 2023. NSE năm 2022 là $-74,054$, phản ánh việc mô hình lặp lại mức lưu lượng cao của năm 2021 trong khi thực tế năm 2022 thấp hơn nhiều. Đây là minh chứng mạnh nhất cho việc không nên dùng Seasonal Naive cho chuỗi có mức nền thay đổi.

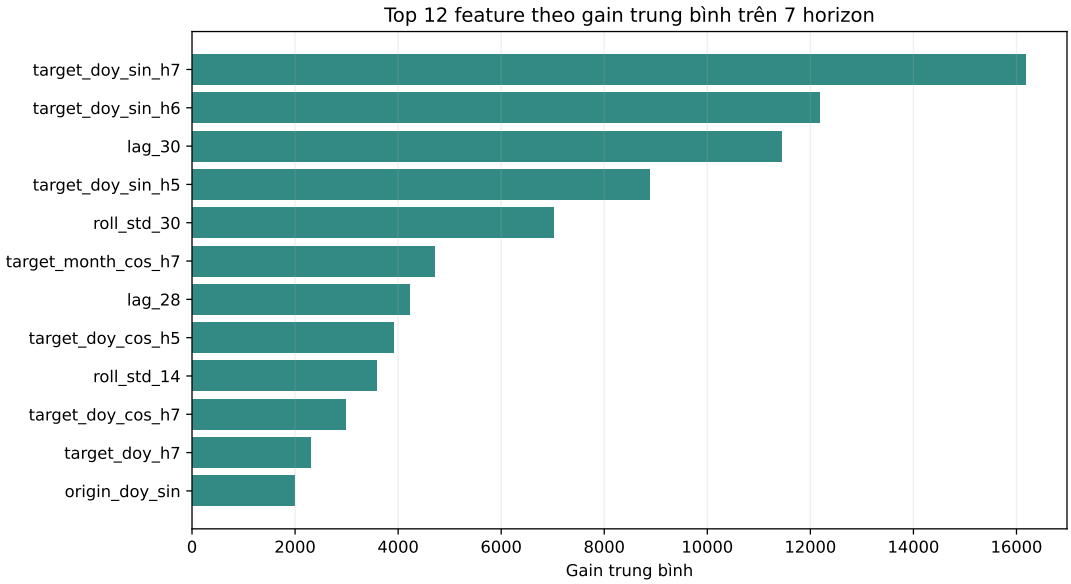
5.8 Mức độ quan trọng của đặc trưng

Bảng 14 và Hình 9 tổng hợp mean gain của các đặc trưng qua bảy mô hình. Đứng đầu là `target_doy_sin_h7`, tiếp theo là `target_doy_sin_h6`, `lag_30`, `target_doy_sin_h5` và `roll_std_30`. Việc các đặc trưng lịch của ngày mục tiêu

xuất hiện ở nhóm đầu cho thấy mô hình sử dụng vị trí mùa để điều chỉnh dự báo, dù mùa vụ yếu. Các lag dài (28, 30 ngày) và độ lệch chuẩn rolling 30 ngày cũng quan trọng, phản ánh mức nền và độ bất định gần đây.

Hạng	Feature	Mean gain	Tỷ trọng (%)
1	target_doy_sin_h7	16.171,46	16,50
2	target_doy_sin_h6	12.170,66	12,42
3	lag_30	11.432,03	11,67
4	target_doy_sin_h5	8.869,39	9,05
5	roll_std_30	7.023,35	7,17
6	target_month_cos_h7	4.714,40	4,81
7	lag_28	4.212,61	4,30
8	target_doy_cos_h5	3.904,04	3,98
9	roll_std_14	3.583,02	3,66
10	target_doy_cos_h7	2.978,14	3,04
11	target_doy_h7	2.299,89	2,35
12	origin_doy_sin	1.982,94	2,02
13	target_month_cos_h6	1.852,88	1,89
14	target_doy_cos_h4	1.800,94	1,84
15	target_month_cos_h5	1.151,80	1,18

Bảng 14: 15 đặc trưng có mean gain cao nhất, tổng hợp qua bảy mô hình horizon.

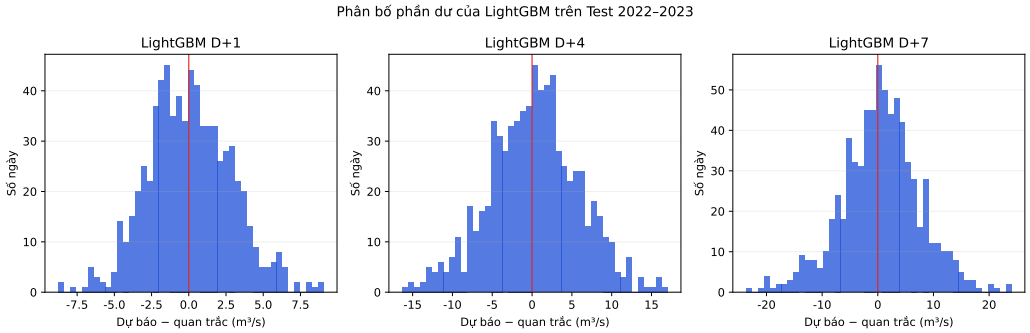


Hình 9: Mean gain của các đặc trưng LightGBM.

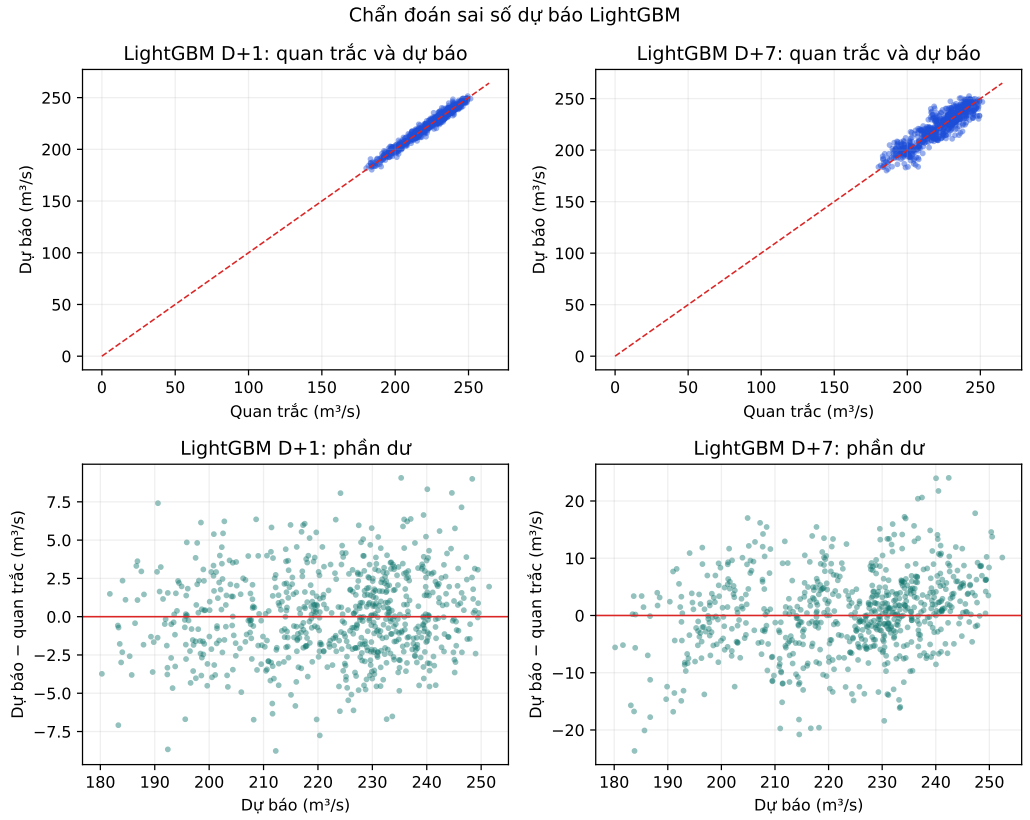
Cần thận trọng khi diễn giải gain: đây là thước đo mức đóng góp của đặc trưng trong các cây đã học, không phải quan hệ nhân quả. Một đặc trưng có gain cao có thể chỉ đang giúp mô hình chia tách các giai đoạn mức nền, chứ không chứng minh rằng nó tạo ra lưu lượng. Ngoài ra, gain được tổng hợp qua các horizon có thang đo khác nhau; so sánh giữa các horizon nên được thực hiện riêng, không chỉ dựa vào bảng tổng hợp.

5.9 Chẩn đoán phần dư và ví dụ dự báo

Hình 10 và Hình 11 cho thấy phần dư của LightGBM phân bố quanh 0 nhưng độ rộng tăng theo horizon. Ở D+1, phần lớn sai số nằm trong khoảng ± 4 m^3/s; ở D+7, khoảng sai số mở rộng lên khoảng ± 12 m^3/s. Bias trung bình của LightGBM là 0,27 m^3/s, trong khi Naive là 0,07; bias nhỏ so với RMSE, nhưng cho thấy mô hình có xu hướng dự báo cao hơn thực tế một chút.

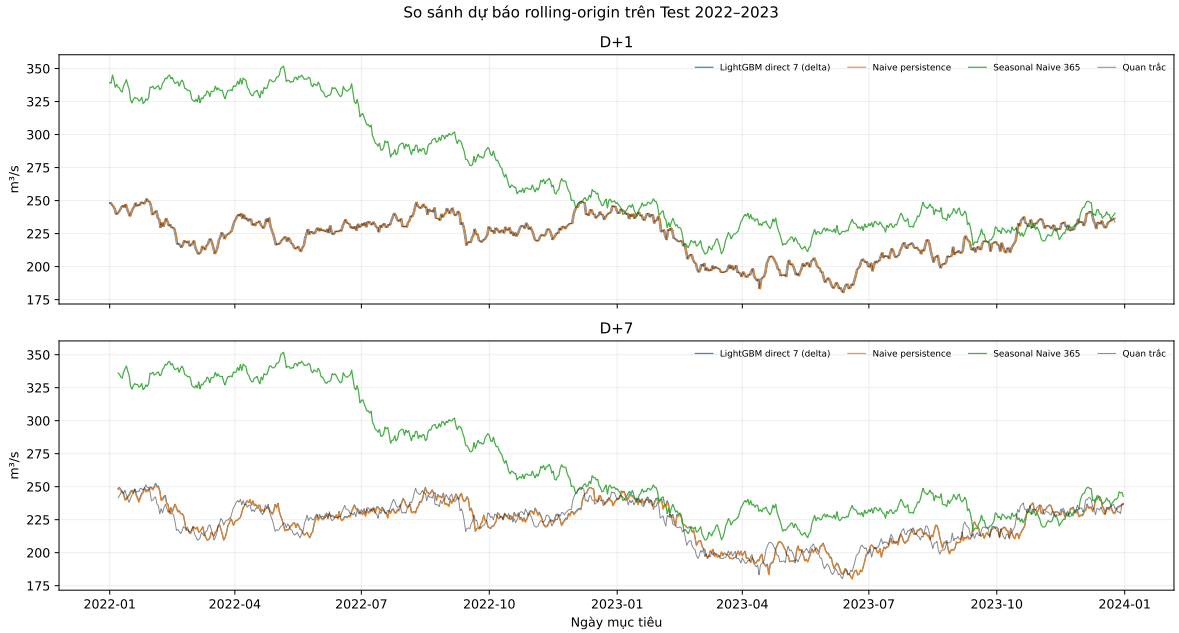


Hình 10: Phân bố phần dư của LightGBM trên Test.



Hình 11: Quan trắc và dự báo của LightGBM ở D+1 và D+7, kèm phần dư.

Hình 12 minh họa dự báo rolling-origin trên toàn bộ Test. Cả Naive và LightGBM bám sát chuỗi quan trắc; Seasonal Naive tạo các đoạn nhảy lớn khi mức nền giữa các năm thay đổi. Đây là hình ảnh trực quan của kết quả trong Bảng 11: mô hình đơn giản nhất lại là mô hình khó bị đánh bại trong chuỗi này.



Hình 12: Dự báo rolling-origin ở D+1 và D+7 trên Test 2022–2023.

Một hạn chế quan trọng là Test 2022–2023 không có ngày nào vượt Q95. Vì vậy báo cáo *không thể* đánh giá khả năng dự báo cực trị của mô hình. Các chỉ số tốt trên Test chủ yếu phản ánh khả năng bám mức nền và biến động thông thường, không phản ánh khả năng cảnh báo lũ. Nếu muốn đánh giá cực trị, cần một tập Test có ít nhất một số đợt vượt ngưỡng, hoặc dùng thiết kế đánh giá riêng cho các đợt cực trị.

5.10 Trả lời câu hỏi 3

Các kết quả chính:

- LightGBM direct 7 đạt mean RMSE 5,33 và NSE 0,881 trên Test, gần tương đương Naive (5,31 và 0,881) và tốt hơn rất nhiều so với Seasonal Naive 365 (60,48 và $-13,333$).
- Khoảng cách LightGBM–Naive chỉ khoảng 0,02 m^3/s (0,3%); không có bằng chứng thuyết phục rằng mô hình học máy vượt trội.
- Sai số tăng theo horizon: D+1 có RMSE khoảng 2,79 và NSE 0,970; D+7 có RMSE khoảng 7,10 và NSE 0,802.
- Năm 2022 khó hơn 2023 theo NSE; Seasonal Naive thất bại nặng vào 2022 do mức nền thay đổi.
- Test không có ngày vượt Q95, nên không thể kết luận về khả năng dự báo cực trị từ kết quả này.

Kết luận thực hành là: trong chuỗi có tính dai dẳng cao và mùa vụ yếu, một baseline đơn giản như Naive là đối thủ mạnh. LightGBM có thể dùng để thử nghiệm các đặc trưng bổ sung, nhưng cần đánh giá cẩn thận và không nên mặc định rằng mô hình phức tạp hơn sẽ tốt hơn.

6. Website kết quả và khả năng tái lập

6.1 Mục tiêu và địa chỉ công khai

Báo cáo không chỉ trình bày kết quả trong tệp PDF mà còn công bố một website tĩnh để người đọc có thể kiểm tra dữ liệu, biểu đồ và dự báo một cách trực quan. Website có địa chỉ:

https://huyduong5.github.io/colorado-river-flow-atlas/

Mã nguồn công khai nằm tại:

https://github.com/huyduong5/colorado-river-flow-atlas

Website được thiết kế để trả lời ba câu hỏi: dữ liệu trông như thế nào; các phát hiện chính về xu hướng, mùa vụ và cực trị ra sao; mô hình dự báo hoạt động thế nào. Mỗi trang đều có liên kết đến dữ liệu gốc hoặc tệp kết quả tương ứng, để người đọc không phải tin vào hình ảnh mà không có nguồn.



Hình 13: Mã QR đến website kết quả (trái) và kho mã nguồn (phải).

6.2 Kiến trúc website

Website là một ứng dụng React viết bằng TypeScript, được đóng gói bằng Vite. Dữ liệu không được nhúng trực tiếp vào mã nguồn mà được đọc từ các tệp JSON/CSV trong `public/data`. Cách tách dữ liệu khỏi giao diện giúp website có thể cập nhật kết quả mà không phải sửa component. Các biểu đồ dùng ECharts; bảng và thẻ số liệu dùng component React thuần.

Cấu trúc chính:

- `code/src/colorado_flow/export_web.py`: sinh dữ liệu JSON cho website từ kết quả pipeline.
- `code/web/public/data/`: dữ liệu đã xuất, gồm manifest, chuỗi thời gian, sự kiện cực trị, dự báo và chỉ số mô hình.
- `code/web/src/pages/`: tám trang giao diện.
- `code/web/src/components/`: layout, biểu đồ, bảng, thẻ số liệu và thành phần điều hướng.

- `.github/workflows/deploy-pages.yml`: build và triển khai lên GitHub Pages mỗi khi push lên nhánh `main`.

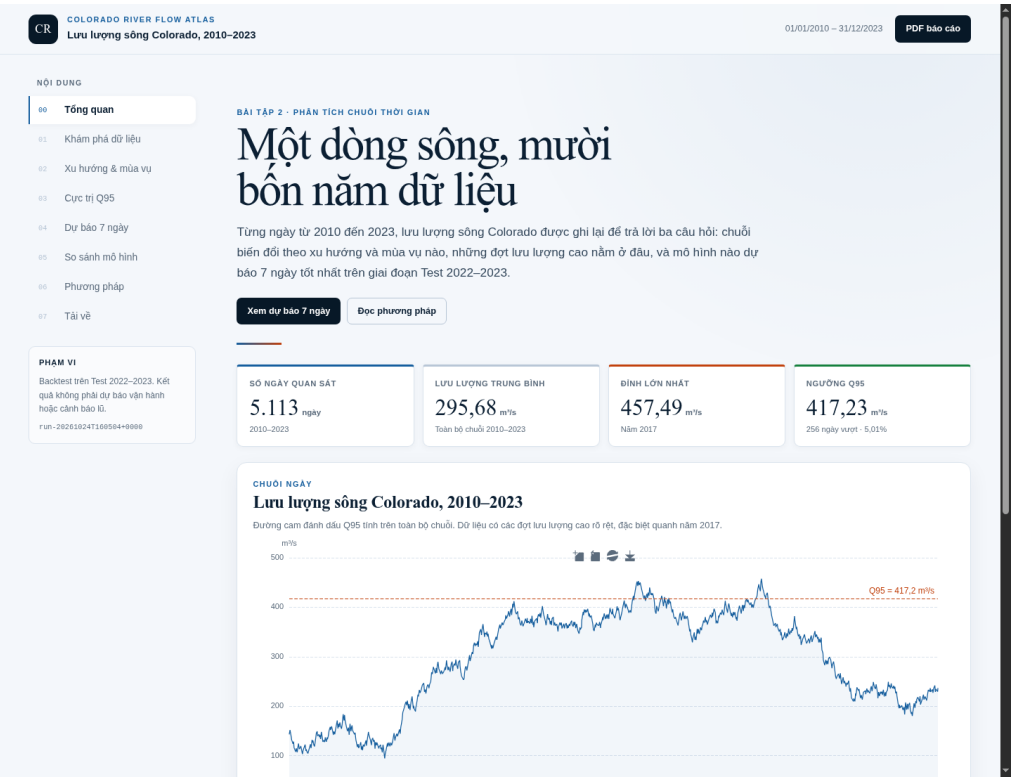
Vite được cấu hình với `base: './'` để các tệp tĩnh hoạt động đúng khi website được phục vụ từ thư mục con của GitHub Pages. Điều hướng dùng hash routing, nhờ đó việc tải lại một trang con không tạo yêu cầu 404 trên máy chủ tĩnh. Đây là những chi tiết kỹ thuật nhỏ nhưng quan trọng để website công khai hoạt động ổn định.

6.3 Các trang và nội dung

Bảng 15 liệt kê tám trang. Mỗi trang có một mục tiêu riêng, tránh lặp lại cùng một biểu đồ ở nhiều nơi.

Trang	Nội dung chính
Tổng quan	Thẻ KPI, tóm tắt phát hiện, liên kết nhanh đến các phần.
Khám phá dữ liệu	Chuỗi thời gian, phân bố, thống kê mô tả, bảng dữ liệu.
Xu hướng & mùa vụ	Trung bình theo tháng/năm, STL, ACF, nhận xét.
Cực trị Q95	Ngưỡng, số ngày, số đợt, bảng sự kiện, bản đồ nhiệt.
Dự báo 7 ngày	Dự báo rolling-origin, bảng chỉ số theo horizon.
So sánh mô hình	RMSE/MAE/NSE, so sánh Naive, Seasonal và LightGBM.
Phương pháp	Pipeline, split, đặc trưng, tham số, giới hạn.
Tải về	PDF, source ZIP, dữ liệu CSV, manifest và checksum.

Bảng 15: Các trang chính của website kết quả.

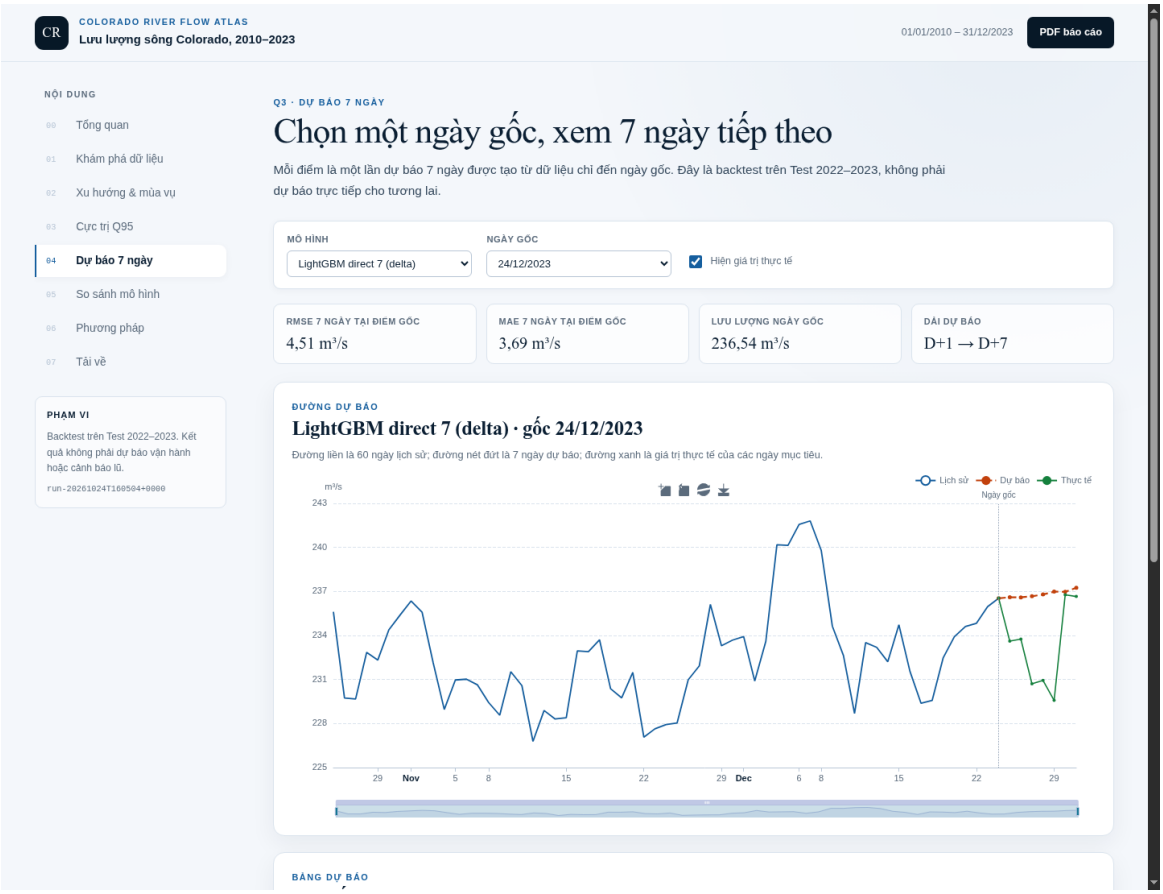


Hình 14: Trang Tổng quan với các thẻ KPI và tóm tắt phát hiện.

Hình 14 cho thấy trang Tổng quan đặt các con số quan trọng ở vị trí dễ thấy: số ngày, lưu lượng trung bình, ngưỡng Q95, số đợt và kết quả mô hình. Các thẻ này được sinh từ cùng một manifest với báo cáo, nên nếu pipeline chạy lại, website và báo cáo cùng thay đổi.

6.4 Trang dự báo và tương tác

Trang Dự báo cho phép chọn horizon và xem chuỗi dự báo so với quan trắc. Hình 15 là ảnh chụp trang này ở kích thước desktop. Biểu đồ chính hiển thị dự báo rolling-origin; bảng bên dưới tóm tắt RMSE, MAE và NSE theo horizon. Người đọc có thể đối chiếu với Bảng 12 trong báo cáo.

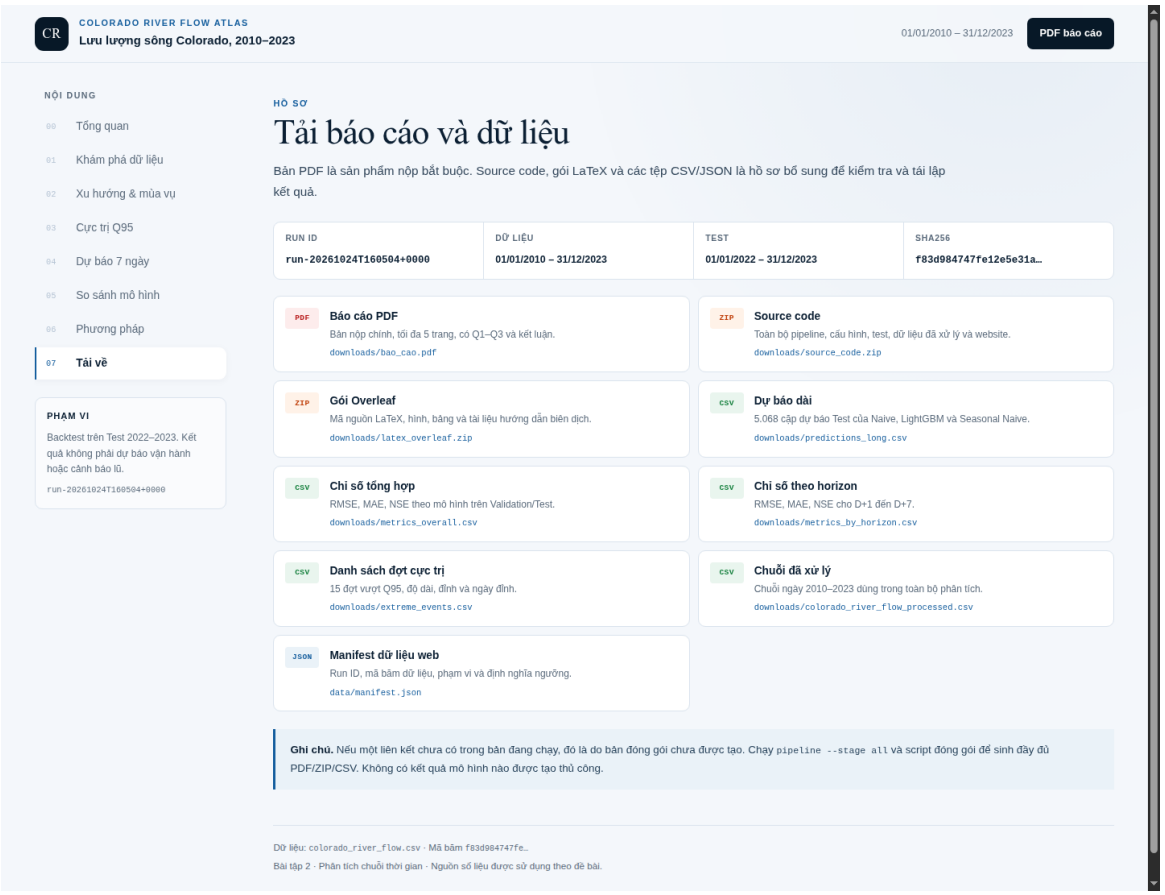


Hình 15: Trang Dự báo 7 ngày với biểu đồ rolling-origin và bảng chỉ số.

Website không chạy mô hình trong trình duyệt. Mọi dự báo được tính sẵn trong pipeline và lưu thành tệp JSON. Cách làm này giữ website nhẹ, không cần backend và bảo đảm rằng người đọc nhìn thấy đúng kết quả đã được đánh giá, không phải một lần chạy mô hình ngẫu nhiên khác. Đổi lại, website không thể nhận dữ liệu mới theo thời gian thực; muốn cập nhật phải chạy lại pipeline và deploy.

6.5 Trang tải về và tính minh bạch

Trang Tải về cung cấp báo cáo PDF, mã nguồn, dữ liệu đã xử lý và manifest. Mỗi tệp có tên rõ ràng và kèm checksum trong `SHA256SUMS`. Hình 16 là ảnh chụp trang này.



Hình 16: Trang Tải về với báo cáo, mã nguồn, dữ liệu và checksum.

Việc công bố cả báo cáo, mã nguồn và dữ liệu giúp người đọc kiểm tra lại kết quả. Tuy nhiên, cần phân biệt ba mức tái lập: (i) tái lập số liệu từ dữ liệu đã xử lý; (ii) tái lập từ dữ liệu thô bằng pipeline; (iii) tái lập trong một môi trường phần mềm khác. Báo cáo hỗ trợ mức (i) và (ii) thông qua script, manifest và seed; mức (iii) phụ thuộc vào phiên bản thư viện và có thể thay đổi nhẹ do thuật toán tối ưu.

6.6 Hiển thị trên thiết bị nhỏ

Website được kiểm tra ở kích thước desktop và mobile. Hình 17 là ảnh chụp ở chiều rộng 375 px. Trên màn hình nhỏ, thanh điều hướng thu gọn, các thẻ KPI xếp thành một cột và bảng có thể cuộn ngang. Mục tiêu không phải là tối ưu cho mọi thiết bị mà là bảo đảm nội dung chính vẫn đọc được trên điện thoại.



Hình 17: Website ở chiều rộng 375 px.

6.7 Triển khai và kiểm tra

Website được triển khai tự động bằng GitHub Actions. Workflow chạy khi có push lên `main`: cài dependency bằng `npm ci`, chạy `npm run build`, tải thư mục `dist` lên GitHub Pages và deploy. Trong quá trình phát triển, workflow đã chạy thành công; website công khai trả về HTTP 200. Các tệp PDF và source trong trang Tải về đã được kiểm tra bằng mã băm so với bản local.

Một điểm cần lưu ý là GitHub Actions có thể hiển thị cảnh báo về phiên bản Node.js của các action. Cảnh báo này không làm workflow thất bại trong lần chạy hiện tại, nhưng cần được theo dõi khi GitHub thay đổi môi trường runner. Đây là vấn đề vận hành, không ảnh hưởng đến nội dung khoa học của báo cáo.

6.8 Giới hạn của website

Website là kênh trình bày, không phải hệ thống cảnh báo. Nó không có backend, không cập nhật dữ liệu thời gian thực và không đưa ra khuyến nghị vận hành. Các dự báo được tính sẵn từ một lần chạy pipeline; nếu dữ liệu hoặc mô hình thay đổi, cần chạy lại và deploy. Ngoài ra, website không thay thế báo cáo PDF: các lập luận, giới hạn và trích dẫn đầy đủ nằm trong báo cáo, còn website tập trung vào tra cứu nhanh.

7. Thảo luận

7.1 Điều gì quyết định kết quả?

Kết quả nổi bật nhất của báo cáo không phải là một mô hình có RMSE thấp, mà là việc một baseline đơn giản như Naive persistence lại khó bị đánh bại. Điều này không quá ngạc nhiên nếu nhìn vào ACF: lưu lượng hôm nay tương quan rất mạnh với lưu lượng những ngày trước, và mức nền thay đổi chậm. Trong một chuỗi như vậy, phần lớn thông tin dự báo ngắn hạn nằm ở giá trị gần nhất; mô hình học máy chỉ có thể cải thiện nếu nó học được phần thay đổi nhỏ vượt trên tính dai dẳng.

LightGBM được thiết kế với mục tiêu delta để tận dụng chính tính dai dẳng này. Nếu mô hình dự báo delta bằng 0, nó trở thành Naive; nếu dự báo delta khác 0, nó cố gắng cải thiện. Trên Validation và Test, các delta học được có ích ở một số thời điểm nhưng không đủ để tạo ra cải thiện tổng thể. Kết quả là LightGBM gần như trùng Naive ở D+1–D+3 và kém hơn một chút ở D+5–D+7. Đây là một kết quả *âm tính có ý nghĩa*: nó cho thấy mô hình phức tạp không tự động tốt hơn trong dữ liệu có cấu trúc đơn giản.

Các lần thử tham số cũng cho thấy điều tương tự. Tám cấu hình khác nhau cho mean RMSE từ 5,57 đến 5,58; khoảng cách quá nhỏ so với độ bất định của hai năm Test. Việc tối ưu tham số không phải là nút thắt chính. Nút thắt là thông tin: chuỗi chỉ có một biến, không có mưa, nhiệt độ, tuyết tan hay vận hành hồ chứa. Những biến này có thể giải thích phần thay đổi mà lag và rolling window không nắm được.

7.2 So sánh với kỳ vọng và tài liệu

Trong lý thuyết dự báo chuỗi thời gian, các mô hình đơn giản thường là baseline bắt buộc, đặc biệt khi chuỗi có tính dai dẳng cao [1]. Kết quả của báo cáo phù hợp với nguyên tắc này: trước khi kết luận một mô hình học máy tốt hơn, cần so sánh với Naive trên cùng tập đánh giá. Việc báo cáo giữ Naive trong mọi bảng so sánh là cần thiết, không phải hình thức.

Seasonal Naive 365 thất bại vì giả định mùa vụ năm ổn định. Phân rã STL cho thấy thành phần mùa vụ yếu hơn nhiều so với thành phần xu hướng; ACF ở độ trễ 365 ngày còn âm nhẹ. Điều này không có nghĩa là chuỗi không có mùa vụ, mà là mùa vụ không đủ mạnh và ổn định để dùng làm dự báo trực tiếp. Khi mức nền thay đổi giữa các năm, việc lặp lại cùng ngày năm trước có thể tạo sai số lớn hơn cả một mô hình "không học" gì ngoài giá trị gần nhất.

LightGBM là một triển khai gradient boosting hiệu quả [4]; tuy nhiên, sức mạnh của nó phụ thuộc vào đặc trưng và dữ liệu. Với 29 đặc trưng nội tại của một chuỗi, mô hình có thể học các tương tác phi tuyến nhưng không thể tạo ra thông tin mới. Feature importance cho thấy các đặc trưng lịch và lag dài được dùng nhiều; điều này hợp lý nhưng cũng cảnh báo rằng mô hình có thể đang học các quy luật mức nền thay vì quan hệ nhân quả. Vì vậy không nên diễn giải gain như bằng chứng nhân quả.

7.3 Giới hạn dữ liệu và thiết kế

Báo cáo có một số giới hạn cần được nêu rõ:

- **Một chuỗi, một trạm:** không thể đánh giá khả năng tổng quát hóa sang trạm khác hoặc sang lưu vực khác.
- **Không có biến ngoại sinh:** thiếu mưa, nhiệt độ, tuyết tan, bốc hơi và vận hành hồ chứa; đây có thể là phần lớn nguyên nhân của các thay đổi mức nền.
- **Test ngắn:** chỉ hai năm 2022–2023; kết quả có thể thay đổi nếu chọn giai đoạn Test khác.
- **Không có cực trị trong Test:** 2022–2023 không có ngày vượt Q95, nên không thể đánh giá khả năng dự báo lũ.
- **Ngưỡng Q95 toàn mẫu:** ngưỡng được tính trên toàn bộ 2010–2023, không phải ngưỡng trượt; phù hợp mô tả nhưng không phù hợp vận hành.
- **Không có khoảng bất định:** báo cáo chỉ đưa ra dự báo điểm, không có khoảng tin cậy hoặc phân phối dự báo.
- **Không có kiểm định ADF/KPSS:** kết luận về tính dừng dựa trên ACF và STL, không dựa trên kiểm định chính thức.
- **Không có GRU/LSTM:** môi trường không cài PyTorch; báo cáo không đưa ra kết quả cho các mô hình này.

Những giới hạn này không làm kết quả hiện tại mất giá trị, nhưng chúng xác định phạm vi diễn giải. Kết quả đúng nhất khi được đọc là: "trong dữ liệu 2010–2023, với các đặc trưng nội tại và split đã chọn, LightGBM không vượt Naive"; không phải "LightGBM không thể dự báo chuỗi này" hay "không mô hình nào có thể tốt hơn".

7.4 Hướng cải thiện

Có bốn hướng cải thiện tự nhiên. Thứ nhất, bổ sung biến ngoại sinh như mưa, nhiệt độ, tuyết tan và thông tin vận hành hồ chứa; đây là hướng có khả năng tạo cải thiện lớn nhất. Thứ hai, dùng đánh giá xác suất (quantile regression, conformal prediction) để trả lời câu hỏi "dự báo có thể sai bao nhiêu", thay vì chỉ một con số điểm. Thứ ba, thử nghiệm ngưỡng cực trị trượt và đánh giá riêng trên các đợt cực trị. Thứ tư, mở rộng sang nhiều trạm hoặc nhiều lưu vực để kiểm tra khả năng tổng quát hóa.

Với mô hình, có thể thử các biến thể như LightGBM với monotonic constraints, mô hình tuyến tính có lag, hoặc mô hình trạng thái (state-space). Tuy nhiên, mọi biến thể cần được so sánh với Naive trên cùng split và cùng horizon. Nếu không có cải thiện rõ ràng, giữ baseline đơn giản là lựa chọn hợp lý hơn về chi phí vận hành và khả năng giải thích.

7.5 Ý nghĩa thực hành

Trong bối cảnh ra quyết định, kết quả này nhắc rằng một mô hình phức tạp cần được chứng minh bằng thực nghiệm, không nên giả định trước. Với chuỗi lưu lượng có tính dai dẳng cao, dự báo ngắn hạn có thể dùng persistence làm mốc; mô hình học máy chỉ nên được thêm vào nếu có bằng chứng cải thiện ngoài mẫu.

Đồng thời, cần theo dõi mức nền và các giai đoạn chuyển chế độ, vì đó là nơi các mô hình dựa trên mùa vụ dễ sai nhất.

Cuối cùng, việc công bố mã nguồn, dữ liệu và website giúp người đọc kiểm tra lại các kết luận. Đây là một phần của chất lượng báo cáo: không chỉ trình bày kết quả mà còn cho thấy cách tạo ra kết quả đó.

8. Kết luận

Báo cáo đã phân tích chuỗi lưu lượng dòng chảy sông Colorado giai đoạn 2010–2023 và trả lời ba nhóm câu hỏi đặt ra. Về cấu trúc chuỗi, dữ liệu có 5.113 ngày, không thiếu, không trùng và không có giá trị bất thường về miền xác định. Chuỗi có tính dai dẳng ngắn hạn rất mạnh, mùa vụ theo tháng yếu và mức nền thay đổi theo từng giai đoạn. Xu hướng STL không tuyến tính: mức nền tăng từ đầu giai đoạn, đạt đỉnh ở giữa và giảm trong những năm gần đây. Đây là đặc điểm quan trọng nhất cần được tính đến khi chọn mô hình.

Về cực trị, ngưỡng Q95 là 417,23 m^3/s, tương ứng z tĩnh 1,224. Có 256 ngày vượt ngưỡng, chiếm 5,01%, và 15 đợt. Các đợt tập trung vào 2017–2018 và 2020; đợt dài nhất kéo dài 90 ngày. Phân bố theo tháng không tạo thành một mùa vụ cố định, và ngưỡng toàn mẫu chỉ phù hợp cho mục tiêu mô tả, không phù hợp cho vận hành.

Về dự báo, LightGBM direct 7 đạt mean RMSE 5,33 và NSE 0,881 trên Test, gần tương đương Naive (5,31 và 0,881) và tốt hơn nhiều so với Seasonal Naive 365 (60,48). Khoảng cách giữa LightGBM và Naive chỉ khoảng 0,3%, không đủ để khẳng định mô hình học máy vượt trội. Sai số tăng theo horizon; D+1 có RMSE khoảng 2,79 và NSE 0,970, trong khi D+7 có RMSE khoảng 7,10 và NSE 0,802. Test không có ngày vượt Q95, nên báo cáo không thể kết luận về khả năng dự báo cực trị.

Ba bài học chính rút ra là: (i) baseline đơn giản phải được đánh giá nghiêm túc trước khi thêm mô hình phức tạp; (ii) mùa vụ yếu và mức nền thay đổi có thể khiến các mô hình dựa trên "cùng ngày năm trước" thất bại; (iii) chất lượng dữ liệu và khả năng tái lập quan trọng không kém độ phức tạp của mô hình. Website kết quả, mã nguồn và manifest được công bố để người đọc có thể kiểm tra lại từng con số.

Hướng phát triển tiếp theo là bổ sung biến ngoại sinh, đánh giá xác suất, dùng ngưỡng cực trị trượt và mở rộng sang nhiều trạm. Trước khi làm những việc đó, cần giữ nguyên nguyên tắc: mọi cải thiện phải được chứng minh trên dữ liệu ngoài mẫu, với cùng split và cùng baseline. Trong phạm vi dữ liệu hiện có, kết luận trung thực nhất là LightGBM chưa vượt được Naive, và báo cáo trình bày kết quả đó thay vì che giấu bằng một phép so sánh có lợi.

Tài liệu tham khảo

[1] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. https://otexts.com/fpp3/

[2] Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3–73.

[3] Nash, J. E., & Sutcliffe, J. V. (1970). River flow forecasting through conceptual models part I — A discussion of principles. *Journal of Hydrology*, 10(3), 282–290.

[4] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.

[5] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.

[6] Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437–450.

[7] McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.

[8] Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.

[9] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.

[10] Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96.

A. Toàn bộ các đợt vượt Q95

Bảng 16 liệt kê đầy đủ 15 đợt, bao gồm ngày bắt đầu, ngày kết thúc, số ngày, ngày đỉnh và lưu lượng đỉnh. Các đợt được sắp xếp theo thời gian.

Mã	Bắt đầu	Kết thúc	Số ngày	Ngày đỉnh	Đỉnh (m³/s)	Ngày vượt
E01	02/06/2017	02/06/2017	1	02/06/2017	419,44	1
E02	04/06/2017	07/06/2017	4	05/06/2017	422,87	4
E03	10/06/2017	10/06/2017	1	10/06/2017	418,28	1
E04	13/06/2017	28/08/2017	77	06/07/2017	453,52	77
E05	02/09/2017	05/09/2017	4	03/09/2017	423,71	4
E06	15/09/2017	14/11/2017	61	11/10/2017	439,97	61
E07	09/01/2018	09/01/2018	1	09/01/2018	417,66	1
E08	13/01/2018	16/01/2018	4	14/01/2018	423,21	4
E09	19/01/2018	19/01/2018	1	19/01/2018	417,91	1
E10	21/01/2018	23/01/2018	3	23/01/2018	418,78	3
E11	04/02/2018	07/02/2018	4	06/02/2018	420,85	4
E12	11/03/2018	13/03/2018	3	12/03/2018	418,79	3
E13	29/11/2019	29/11/2019	1	29/11/2019	417,40	1
E14	02/02/2020	02/02/2020	1	02/02/2020	417,46	1
E15	04/02/2020	03/05/2020	90	10/03/2020	457,49	90

Bảng 16: Toàn bộ các đợt lưu lượng vượt Q95 trong giai đoạn 2010–2023.

B. Thống kê lưu lượng theo năm

Bảng 17 bổ sung thống kê theo năm cho phân tích ở câu hỏi 1. Các giá trị được tính trên toàn bộ ngày trong năm, không phải trung bình của các tháng.

Năm	n	Mean	Median	SD	Min	P95	Max
2010	365	129,01	128,44	15,22	103,28	154,22	160,82
2011	365	139,65	135,27	19,41	111,01	172,77	185,86
2012	366	176,56	193,78	45,89	94,39	240,40	246,60
2013	365	277,89	278,14	15,51	236,31	305,51	328,24
2014	365	358,01	356,51	25,17	316,27	400,14	412,01
2015	365	371,48	370,66	9,29	350,52	388,11	402,06
2016	366	373,73	370,38	13,17	346,57	394,87	398,21
2017	365	411,57	408,96	20,68	373,61	448,42	453,52
2018	365	377,56	377,62	25,01	328,91	416,53	423,21
2019	365	391,50	390,80	12,99	362,92	412,08	417,40
2020	366	382,61	366,30	36,49	330,80	443,42	457,49
2021	365	305,25	313,55	32,81	244,42	342,80	351,85
2022	365	231,00	230,35	9,59	209,54	246,67	251,39
2023	365	213,61	212,16	16,43	180,26	239,48	243,57

Bảng 17: Thống kê lưu lượng theo năm, 2010–2023.

C. Manifest và kiểm tra tính nhất quán

Bảng 18 tóm tắt các thông tin nhận dạng của lần chạy. Các thông tin này được lưu trong `run_manifest.json`, `data_quality.json` và `model_selection.json`. Nếu một trong các giá trị này thay đổi, kết quả trong báo cáo không còn tương ứng với lần chạy mới.

Trường	**Giá trị**
Run ID	`run-20261024T160504+0000`
Dataset hash	`f83d984747fe`... (đầy đủ trong manifest)
Config hash	`b45e27e26f42`... (đầy đủ trong manifest)
Seed	42
Số ngày dữ liệu	5.113
Số gốc Test	724
Số cặp Test mỗi mô hình	5.068
Ngưỡng Q95	417,23 m^3/s
Số đợt vượt Q95	15
Số bảng / hình full	14 / 14
Python	3.12.3
pandas	3.1.0
NumPy	2.5.4
statsmodels	0.15.0
LightGBM	4.7.0
Matplotlib	3.11.2

Bảng 18: Thông tin nhận dạng và phiên bản phần mềm của lần chạy.

Các kiểm tra tự động đã chạy gồm: audit dữ liệu, kiểm tra split không xáo trộn, kiểm tra biên ngày mục tiêu, 15 bài test Python và build website. Kết quả test không thay thế kiểm tra khoa học, nhưng bảo đảm pipeline không bị lỗi cú pháp hoặc lỗi dữ liệu cơ bản.

D. Hướng dẫn tái lập

Các lệnh dưới đây chạy từ thư mục gốc của dự án. Môi trường được tạo bằng uv; có thể dùng `pip` nếu đã có Python 3.12.

```
cd code
uv venv --system-site-packages .venv
uv pip install --python .venv/bin/python -e .
.venv/bin/python -m colorado_flow.pipeline --stage all
```

Lệnh trên chạy lần lượt audit, EDA, features, train, freeze, evaluate và export. Kết quả nằm trong `code/results`; bảng và hình cho báo cáo nằm trong `latex/` và `latex_full/`.

Để build website:

```
cd code/web
npm ci
npm run build
```

Để build báo cáo đầy đủ bằng Tectonic:

```
cd latex_full
tectonic -X compile main.tex
```

Nếu dùng Overleaf, upload thư mục `latex_full` và đặt `main.tex` làm tệp chính. Các tệp bảng, hình và số liệu đã được sinh sẵn; không cần chạy lại Python trên Overleaf.

E. Ghi chú về hai phiên bản báo cáo

Báo cáo này là bản đầy đủ, được mở rộng từ bản nộp 5 trang theo yêu cầu của người học. Bản 5 trang được giữ trong `latex/` và `deliverables/` (tệp PDF cùng mã sinh viên); bản đầy đủ được build từ `latex_full/main.tex`. Hai phiên bản dùng chung dữ liệu, cùng run ID và cùng bộ kết quả, nên không có mâu thuẫn số liệu giữa bản ngắn và bản dài.

Việc giữ cả hai phiên bản giúp người đọc chọn mức độ chi tiết phù hợp: bản ngắn để nộp đúng giới hạn trang, bản dài để trình bày đầy đủ phương pháp, chẩn đoán và thảo luận. Khi có thay đổi dữ liệu hoặc mô hình, cả hai cần được build lại từ cùng một lần chạy pipeline.